

北京理工大学

本科生毕业设计（论文）

大语言模型医学场景反事实问答基准构建与
因果一致性评测研究

Research on Constructing a Counterfactual Questioning
Benchmark and Evaluating Causal Consistency in Medical
Settings Using Large Language Models

学 院： 计算机学院

专 业： 人工智能

班 级： 07842201

学生姓名： 丘宇翔

学 号： 1820221046

指导教师： 杨旭


2026 年 5 月 27 日

原创性声明

本人郑重声明：所呈交的毕业设计（论文），是本人在指导老师的指导下独立进行研究所取得的成果。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

特此申明。

本人签名：



日期：2026 年 5 月 27 日

关于使用授权的声明


本人完全了解北京理工大学有关保管、使用毕业设计（论文）的规定，其中包括：①学校有权保管、并向有关部门送交本毕业设计（论文）的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存本毕业设计（论文）；③学校可允许本毕业设计（论文）被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换本毕业设计（论文）；⑤学校可以公布本毕业设计（论文）的全部或部分内容。

本人签名：



日期：2026 年 5 月 27 日

指导老师签名：



日期：2026 年 5 月 27 日

大语言模型医学场景反事实问答基准构建与因果一致性 评测研究

摘 要

随着大语言模型在医疗领域的广泛应用，其在临床决策支持中的可靠性问题日益凸显。现有模型常出现“答案表面正确而推理链条不稳定”的现象，即在面对语义等价的问题变体或反事实场景时，模型输出存在逻辑不一致，这在高风险的医学决策场景中可能导致严重后果。然而，传统评测方法主要关注答案准确率，缺乏对推理过程一致性、条件切换稳定性以及安全边界的系统评估。因此，构建面向医学临床决策的因果一致性评测基准，对于提升大语言模型在医疗场景中的安全性与可信度具有重要意义。

本文围绕因果一致性评测需求，构建了 MedCausalBenchmark 评测基准，并系统比较了纯大模型、检索增强生成（RAG）与因果混合推理（CausalSCM 方法）三类方案的表现。首先，基于结构因果模型对临床决策过程进行形式化建模，建立医学问题的结构因果表示，并从逻辑维度与医学维度构建双维度分类体系，以刻画事实、反事实与干扰场景下的推理复杂性。其次，基于权威临床指南，构建了包含 720 条样本的 MedCausalBenchmark 数据集，使每个样本同时具备问题文本、标准答案及相应的因果结构信息，从而支持准确率、一致性、安全性与鲁棒性等多维评测。最后，在五个开源模型上开展系统实验，全面评估不同方案在医学决策任务中的表现。

实验结果表明，CausalSCM 方法的平均准确率达到 88.50%，显著高于 Pure LLM 的 79.89% 和 RAG 的 77.20%；在以 Qwen3-8B 为代表的因果一致性分析中，该方法的 CC、SS 与 RS 分别达到 0.79、0.94 和 0.86，CCR 降至 0.06，整体表现均优于对比方案。进一步分析发现，显式因果结构的主要价值不在于简单增加外部知识，而在于约束推理路径、突出关键条件并压缩高风险错误空间。本文研究为医学大语言模型的可靠性评估提供了可复用的基准与分析框架，也为临床决策支持系统中的安全部署提供了方法参考，未来可进一步扩展至多模态医学数据与实时临床场景的评测。

关键词：大语言模型；医学反事实推理；因果一致性；知识图谱；临床决策支持

Research on Constructing a Counterfactual Questioning Benchmark and Evaluating Causal Consistency in Medical Settings Using Large Language Models

Abstract

With the widespread application of large language models in healthcare, their reliability in clinical decision support has become increasingly critical. Existing models often exhibit the phenomenon of "superficially correct answers with unstable reasoning chains," manifesting logical inconsistencies when facing semantically equivalent question variants or counterfactual scenarios. Such inconsistencies may lead to severe consequences in high-risk medical decision-making contexts. However, traditional evaluation methods primarily focus on answer accuracy, lacking systematic assessment of causal consistency in reasoning processes. Therefore, constructing a causal consistency evaluation benchmark for medical clinical decision-making is of great significance for enhancing the safety and trustworthiness of large language models in healthcare scenarios.

This thesis constructs MedCausalBenchmark, a benchmark for evaluating causal consistency, and systematically compares three paradigms: Pure LLM, retrieval-augmented generation (RAG), and causal hybrid reasoning (CausalSCM). First, the study formulates clinical decision processes through structural causal models, establishing structural causal representations of medical problems and building a dual-dimensional taxonomy from both logical and medical perspectives to characterize reasoning complexity across factual, counterfactual, and interference-driven scenarios. Second, based on authoritative clinical guidelines, a dataset of 720 samples is developed, in which each instance contains the question text, gold answer, and corresponding causal structure, thereby supporting multidimensional evaluation in terms of accuracy, consistency, safety, and robustness. Finally, systematic experiments are conducted on five open-source models to comprehensively evaluate the performance of different approaches in medical decision tasks.

The experimental results show that CausalSCM achieves an average accuracy of 88.50%, significantly exceeding Pure LLM (79.89%) and RAG (77.20%). In the causal-consistency analysis on Qwen3-8B, it further reaches 0.79 in CC, 0.94 in safety score, and 0.86 in robustness score, while reducing the consistency collapse rate to 0.06, consistently outperforming

both baseline approaches. Further analysis indicates that the main value of explicit causal structure does not lie in merely adding more external knowledge, but in constraining reasoning paths, highlighting clinically decisive conditions, and compressing the space of high-risk errors. This work provides a reusable benchmark and analytical framework for reliability assessment of medical LLMs, and offers methodological support for their safer deployment in clinical decision support systems. Future work may extend to multimodal medical data and real-time clinical scenario evaluation.

Key Words: Large Language Models; Medical Counterfactual Reasoning; Causal Consistency; Knowledge Graph; Clinical Decision Support

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景与问题提出	1
1.1.1 临床决策中的因果推理需求	1
1.1.2 大语言模型在医学领域的应用现状	1
1.1.3 现有医学评测基准的局限性	2
1.2 研究意义	3
1.2.1 理论意义	3
1.2.2 实践意义	3
1.2.3 应用价值	4
1.3 本文主要工作与章节安排	4
1.3.1 主要工作	4
1.3.2 章节安排	5
第 2 章 相关工作	6
2.1 大语言模型推理能力评测研究	6
2.1.1 从知识问答到复杂推理评测的发展	6
2.1.2 一致性与鲁棒性评测研究	7
2.2 因果推理与反事实推理的理论基础	7
2.2.1 Pearl 因果阶梯理论	7
2.2.2 结构因果模型与医学知识建模	8
2.2.3 反事实推理过程与结构一致性要求	9
2.3 因果推理与反事实推理评测研究	9
2.4 医学领域大语言模型发展与评测	10
2.4.1 国外医学大语言模型的发展现状	10
2.4.2 国内中文医学大语言模型的发展现状	11
2.4.3 国外医学评测基准及其局限性	13
2.4.4 国内中文医学评测基准	13
2.4.5 国内中文医学评测的进展与不足	14
2.5 医学知识表示与知识增强方法	15
2.6 因果一致性评测研究	16

2.7 本章小结	17
第3章 医学因果一致性评测体系的设计	18
3.1 临床决策中的因果结构建模	18
3.1.1 医学决策的因果本质	18
3.1.2 反事实推理的形式化定义	19
3.2 双维度因果分类体系	19
3.2.1 分类体系设计原则	19
3.2.2 逻辑维度：因果推理结构复杂度	20
3.2.3 医学维度：因果约束类型	21
3.2.4 双维度分类矩阵与评测覆盖性	22
3.3 因果一致性评测指标体系	23
3.3.1 指标设计的已有研究基础	24
3.3.2 因果一致性的概念界定	24
3.3.3 核心一致性指标	25
3.3.4 多维辅助评测指标	26
3.3.5 错误模式分类体系	27
3.4 评测体系的有效性分析	28
3.4.1 与传统评测方法的对比	28
3.4.2 评测体系的局限性与改进方向	28
3.5 小结	29
第4章 MedCausalBenchmark 数据集构建方法	30
4.1 数据集设计原则	30
4.2 数据源选择与预处理	31
4.2.1 数据源选取标准	31
4.2.2 指南文本预处理	32
4.3 数据集构建流程概览	32
4.4 基于双维度分类的因果场景设计	34
4.4.1 因果场景的形式化定义	34
4.4.2 场景设计的总体策略	34
4.4.3 基础型场景设计	34
4.4.4 联合型场景设计	35
4.4.5 嵌套型场景设计	35
4.4.6 条件型场景设计	36

4.4.7 混杂因素干扰场景设计	36
4.5 问答样本的结构化生成	37
4.5.1 样本数据结构设计	37
4.5.2 事实性问题生成	37
4.5.3 反事实问题生成	38
4.5.4 对抗样本生成	39
4.6 质量控制与数据集统计	39
4.6.1 质量控制流程	39
4.6.2 数据集整体统计	39
4.6.3 疾病覆盖分布	40
4.6.4 双维度交叉分布分析	41
4.6.5 数据集的因果严密性保证	43
4.6.6 与已有医学评测数据集的对比分析	43
4.7 本章小结	44
第5章 系统实现与实验设计	46
5.1 实验环境与技术栈	46
5.1.1 硬件与软件环境	46
5.1.2 大语言模型推理后端	46
5.1.3 数据集与知识库	47
5.2 三类技术方案的系统架构	48
5.2.1 纯大语言模型方案（Pure LLM）	48
5.2.2 检索增强生成方案（RAG）	50
5.2.3 因果规则推理方案（CausalSCM）	52
5.3 实验设置与评测流程	55
5.3.1 模型配置与参数	55
5.3.2 三类方案的实验参数	56
5.3.3 评测流程	57
5.3.4 质量控制措施	57
5.4 小结	58
第6章 实验结果与分析	59
6.1 实验概述	59
6.1.1 数据集及其特点	59
6.1.2 基准方法	60

6.1.3	评估指标	61
6.1.4	实验模型	61
6.2	整体性能分析	62
6.2.1	不同方法的总体表现	62
6.2.2	因果一致性与安全鲁棒性指标	64
6.2.3	与已有评测结果的横向参照	66
6.3	多维度细粒度分析	67
6.3.1	不同问题类型的表现差异	67
6.3.2	不同疾病类别的影响	69
6.3.3	模型规模与架构的作用	70
6.3.4	逻辑维度的分层表现	72
6.3.5	跨模型综合对比	73
6.4	错误分析与能力边界	74
6.4.1	错误类型转移	74
6.4.2	成功案例：知识补偿	75
6.4.3	失败案例：多因素权衡	75
6.4.4	持续错误分布	76
6.5	RAG 方法效果分析	77
6.5.1	RAG 效果受限的原因分析	77
6.5.2	与因果增强的机制差异	77
6.6	因果增强机制分析与理论解释	78
6.6.1	问题重述：因果增强改变了什么	78
6.6.2	因果增强有效性的理论依据	78
6.6.3	因果增强的三层作用机制	78
6.6.4	因果增强的能力边界	79
6.7	小结	79
第 7 章	总结与展望	81
7.1	主要研究工作与研究结论	81
7.1.1	主要研究工作	81
7.1.2	主要研究结论	81
7.2	研究创新点与实际意义	82
7.2.1	研究创新点	82
7.2.2	实际应用意义	83

7.3 研究局限性	83
7.4 未来研究展望	84
7.5 本章小结	85
结 论	86
参考文献	87
附 录	91
致 谢	92

第1章 绪论

1.1 研究背景与问题提出

1.1.1 临床决策中的因果推理需求

临床医学决策的核心在于对干预措施与患者预后之间因果关系的准确判断。与一般的信息检索任务不同，临床决策不仅需要回答“患者当前状态如何”这类描述性问题，更需要回答“如果采取某种治疗方案，患者预后将如何改变”这类反事实推理问题^[1]。这种推理能力对于个体化治疗方案制定、医疗差错分析以及罕见病例处理具有不可替代的价值。

反事实推理（Counterfactual Reasoning）是因果推理的最高层次。根据 Pearl（2009）^[2]提出的因果阶梯理论（Ladder of Causation），因果推理可分为三个层次：关联层（Association）关注变量间的统计相关性，回答“看到什么”的问题；干预层（Intervention）关注主动改变某变量后的效应，回答“做什么”的问题；反事实层（Counterfactual）则探讨“如果当初不同，结果会如何”的假设性问题，回答“为什么”的深层因果机制。在医学场景中，反事实推理的典型应用包括：评估未采取的治疗方案可能产生的效果、分析不同干预时机对预后的影响、识别导致不良结局的关键因素等。

临床实践证明，医学反事实推理能力是精准医疗的关键支撑。例如，在肿瘤治疗中，临床医师需要评估“如果患者不携带特定基因突变，当前的靶向治疗方案是否仍然有效”；在心血管疾病管理中，需要判断“如果患者存在某种合并症，推荐的药物是否会带来不可接受的风险”。这些问题的本质都是反事实推理，要求决策者能够在给定观测事实的基础上，推演出假设性条件下的因果链路变化。

1.1.2 大语言模型在医学领域的应用现状

近年来，大语言模型（Large Language Models, LLMs）在医学自然语言处理领域取得了显著进展^[3]。在医学问答任务方面，Google Health 推出的 Med-PaLM 模型在 MedQA（美国医师执照考试风格题）上达到 67.6% 的准确率^[4]，其后续版本 Med-PaLM 2 进一步将准确率提升至 86.5%，接近人类专家水平（87.0%）^[5]；GPT-4 在 MedQA、PubMedQA 及 MMLU 医学子集等多项基准上持续超越已有的任务特定微调模型，展现出与人类专家相当的医学问答能力^[6]。Zhou 等人^[3]的综述系统梳理了医学大模型

在临床笔记生成、医学文献摘要、患者问诊对话、医学教育等多个下游任务中的应用进展，指出通用大模型与领域适配模型在不同任务上各有优势。与此同时，国内研究也开始关注中文医学大模型（如 ChiMed-GPT 等）、垂直问答系统与医学知识增强方法在临床场景中的应用潜力^[7-9]。

然而，学术界逐渐意识到，大语言模型在标准化医学考试中的优异表现可能主要源于对训练语料中统计模式的强大记忆能力，而非真正的逻辑推理能力^[4,6]。多项研究表明，当前的医学大模型在面临以下挑战时表现不佳：

因果推理能力不足：模型往往停留在“关联”层次，难以稳定跨越到“干预”和“反事实”层次^[10]。例如，模型可能正确回答“长期服用糖皮质激素的患者出现骨质疏松的风险较高”这类基于统计关联的问题，但在面对“如果该患者未曾使用糖皮质激素，其骨质疏松是否仍会发生”这类反事实问题时，需要综合考虑患者年龄、性别、基础疾病等混杂因素，模型往往难以正确区分药物的因果效应与患者本身的基线风险，容易产生逻辑矛盾。

逻辑一致性缺失：模型在回答事实问题和反事实问题时，常常出现自相矛盾的现象^[11]。这种不一致性在医学场景中尤为危险，因为它可能导致临床决策的不可靠性。

幻觉问题严重：模型容易以极高的置信度生成错误的医学推论^[12]。这种“幻觉”现象在涉及罕见疾病、复杂药物相互作用或多步推理的场景中更为突出。

安全性评估缺失：现有评测基准主要关注准确率等单一指标，缺乏对模型在高风险医学场景下安全性的系统评估^[13]。例如，模型是否能够识别禁忌证、是否会推荐高风险治疗方案等关键问题尚未得到充分验证。

1.1.3 现有医学评测基准的局限性

目前已有多个医学大模型评测基准被广泛使用，包括 MedQA^[14]、PubMedQA^[15]、MMLU-Medical^[16]等。这些基准在推动医学 AI 发展方面发挥了重要作用，但在评估模型的因果推理能力方面存在显著局限性：

评测形式单一：现有基准多采用选择题形式，主要测试模型对医学知识的记忆和检索能力，难以评估开放式推理能力^[14]。选择题的答案空间有限，模型可能通过排除法或统计模式匹配获得正确答案，而非真正理解因果机制。

缺乏因果推理评测：大多数基准关注事实性知识的准确性，缺乏对因果推理能

力的系统评估^[17]。例如，MedQA 虽然包含临床推理题目，但主要测试的是“给定症状诊断疾病”这类关联推理，而非“改变干预措施后预后如何变化”这类因果推理。

逻辑一致性未被关注：现有基准通常独立评估每个问题的准确率，忽视了模型在面对相关问题时的逻辑一致性^[18]。一个可靠的临床决策支持系统不仅需要回答正确，更需要在不同条件下保持逻辑自洽。

缺乏反事实样本：现有数据集主要包含事实性问题，缺少系统化的反事实问题设计^[19]。反事实问题对于评估模型的因果理解至关重要，因为它要求模型能够推演假设性场景下的因果链路变化。

医学场景覆盖不足：通用领域的因果推理基准（如 CLadder 等）虽然在理论上具有一定完备性，但其问题主要基于合成数据，与真实医学场景存在较大差距^[10,17]。

针对上述局限性，构建面向医学场景的反事实问答评测基准，系统评估大语言模型的因果推理能力和逻辑一致性，成为医疗 AI 安全部署的迫切需求。

1.2 研究意义

1.2.1 理论意义

本研究的理论意义体现在以下两个方面：

填补医学反事实推理评测的空白：本研究将 Pearl 的因果阶梯理论系统引入医学大模型评测领域，构建了首个面向医学临床决策的反事实问答基准。不同于现有评测主要关注关联层推理，本研究聚焦于因果阶梯的最高层次——反事实推理，为医学 AI 的因果推理能力评估提供了理论框架和实证工具。

提出双维度因果分类体系：本研究创新性地提出了“逻辑维度 × 医学维度”的双维度分类体系。逻辑维度（基础型、联合型、嵌套型、条件型）刻画了因果推理的结构复杂度，医学维度（适应证、禁忌证、混杂因素）反映了临床决策的特殊性。这一体系不仅为数据集构建提供了系统化框架，也为后续研究提供了可扩展的理论基础。

1.2.2 实践意义

本研究的实践意义主要体现在：

提供标准化评测工具：构建的 MedCausalBenchmark 数据集包含 720 条高质量样本，覆盖急性淋巴细胞白血病、前列腺癌、小细胞肺癌等多种疾病场景，为医学大模

型的因果推理能力提供了标准化评测基准。该数据集基于权威临床指南构建，具有医学可靠性和逻辑严密性，可直接用于模型开发和质量评估。

识别模型安全风险：通过因果一致性指标和安全性评测，本研究能够系统识别医学大模型在临床决策中的潜在风险点。例如，模型是否会在存在禁忌证时仍推荐高风险治疗、是否会因混杂因素干扰而产生错误推理等。这些发现为模型的安全部署提供了重要依据。

指导技术方案选择：本研究对比了纯大语言模型（Pure LLM）、检索增强生成（RAG）和因果规则推理（CausalSCM）三种技术方案在因果一致性方面的表现，为医疗 AI 系统的架构设计提供了实证参考。研究结果揭示了外部知识和显式逻辑约束对提升模型可靠性的有效性，为后续系统优化指明了方向。

1.2.3 应用价值

本研究成果具有直接的应用价值：

临床决策支持系统质量评估：医疗机构在引入 AI 辅助诊疗工具时，可使用本研究提供的评测基准进行风险评估，确保系统在因果推理和逻辑一致性方面达到可接受的安全标准。

模型开发与优化：研究揭示的典型失效模式（如关系混淆、权衡错误、推理崩溃等）为模型开发者提供了明确的改进方向。通过针对性优化，可提升模型在医学场景下的可靠性。

监管与认证支持：随着医疗 AI 监管政策的完善，本研究提供的评测体系和指标可为相关部门制定技术标准和认证流程提供参考，推动医疗 AI 的规范化发展。

1.3 本文主要工作与章节安排

1.3.1 主要工作

本文围绕“大语言模型医学反事实推理能力评测”这一核心问题，开展了以下四项工作：

（1）设计面向医学场景的因果一致性评测框架。本文结合 Pearl 因果阶梯理论与临床决策特征，构建了适用于医学问答任务的评测思路，将评测重点从单点正确率扩展到事实、反事实与干扰情境下的推理一致性，为后续实验分析提供统一框架。

（2）构建医学反事实问答数据集 **MedCausalBenchmark**。本文基于权威临床指

南与医学知识结构，构建覆盖多疾病场景、多类型问题的医学反事实问答数据集。数据集中同时包含事实性问题、反事实问题和对抗性问题，用于系统检验模型在医学因果推理任务中的表现。

（3）实现并比较三类医学问答技术方案。本文分别实现纯大语言模型、检索增强生成以及因果约束增强三类方法，并在统一实验环境下进行对比评测，以分析不同知识组织与推理约束方式对模型表现的影响。

（4）分析医学大模型的典型失效模式与安全风险。基于实验结果，本文从关系混淆、权衡错误、推理崩溃等角度分析模型在医学反事实推理中的主要缺陷，并进一步讨论外部知识与显式因果约束对提升模型可靠性的作用。

1.3.2 章节安排

本文共分七章，具体安排如下：

第一章：绪论。介绍研究背景与问题提出，阐明研究意义，并说明本文的主要工作与章节安排。

第二章：相关工作。综述国内外研究现状、大语言模型推理评测、因果推理与反事实推理理论、医学领域大语言模型评测，以及因果一致性评测等相关研究，并明确本文的研究定位。

第三章：医学因果一致性评测体系的设计。围绕临床决策中的因果结构建模，提出双维度分类体系与多维评测指标，构建面向医学反事实推理任务的评测框架。

第四章：MedCausalBenchmark 数据集构建方法。介绍医学因果知识抽取、图谱组织、样本生成与质量控制流程，说明医学反事实问答数据集的构建方法与数据特征。

第五章：系统实现与实验设计。介绍三类技术方案的系统实现、实验环境、参数设置与评测流程，为后续实验结果分析提供实现基础。

第六章：实验结果与分析。对不同模型与方法在 MedCausalBenchmark 上的表现进行系统分析，从整体性能、问题类型、疾病类别、模型差异以及错误归因等多个维度展开讨论。

第七章：总结与展望。总结本文研究结论与创新点，讨论研究局限性，并对未来研究方向进行展望。

第2章 相关工作

随着大语言模型在医学领域的广泛应用，如何系统评估其推理能力成为研究重点。本章在综述相关研究的基础上，对国内外相关工作进行系统梳理。首先综述大语言模型推理能力评测的发展脉络；随后介绍因果推理与反事实推理理论基础；进一步从通用领域与医学领域两个方向综述反事实推理评测研究；接着分别梳理外医学大语言模型与国内中文医学大语言模型的发展现状、医学评测基准以及中文医学评测研究进展；最后总结现有工作的不足，并明确本文研究定位。

2.1 大语言模型推理能力评测研究

2.1.1 从知识问答到复杂推理评测的发展

早期大语言模型评测主要围绕知识记忆与语言理解能力展开，典型任务包括阅读理解、常识推理、多项选择问答以及知识补全等。Hendrycks 等提出的 MMLU 基准^[16]通过覆盖 57 个学科领域，对模型知识广度进行了系统评测；Singhal 等^[4]将类似评测方式扩展至医学领域，提出 Med-PaLM 并在 MedQA 等医学考试任务中验证模型能力；Jin 等^[14]则关注疾病诊断问答场景中的知识获取能力。

然而，后续研究逐渐发现，这类基准更多衡量的是模型对训练语料统计模式的记忆能力，而并非真正意义上的“推理能力”。Dziri 等^[20]指出，大语言模型在分布内任务上往往表现良好，但在结构发生变化、问题表述改写或条件扰动后，性能会明显下降，说明模型推理仍高度依赖表层模式匹配。

随着研究深入，学界开始从“答案正确性”转向“推理过程合理性”的评估。Wei 等^[21]提出思维链提示（Chain-of-Thought, CoT），通过显式生成中间推理步骤提升模型复杂任务表现。随后，Wang 等^[22]提出 Self-Consistency 方法，通过多路径采样缓解推理不稳定问题；Turpin 等^[23]则进一步指出，CoT 虽然增强了模型推理表达能力，但并不能保证推理过程真实可靠。

在医学场景中，这一问题更加突出。医学决策通常涉及多变量因果依赖、治疗禁忌证约束以及风险收益平衡，仅依赖语言表层模式难以完成稳定推理。Liévin 等^[24]指出，当前医学大模型虽然在标准考试中表现突出，但在临床复杂推理与真实诊疗流程中仍存在明显局限。

总体来看，现有大模型评测研究已经从单纯知识性问答逐渐发展到复杂推理分析，但对于“推理结构是否一致”“因果链条是否合理”仍缺乏系统评测机制。这也推动研究者进一步引入因果推理与反事实推理框架。

2.1.2 一致性与鲁棒性评测研究

除准确率之外，研究者开始关注大语言模型推理过程的一致性与稳定性。相关研究主要集中于以下几个方向：

（1）**多轮推理一致性评测**。研究发现，同一模型在不同采样条件、不同提示词甚至不同问题顺序下，可能生成逻辑冲突的回答。Wang 等^[22]指出，大语言模型存在明显的采样敏感性。

（2）**语义扰动鲁棒性评测**。研究者通过同义改写、条件交换、选项顺序调整等方式测试模型稳定性。Dziri 等^[20]发现，许多模型在问题表述发生微小变化后，结论会显著改变。

（3）**因果一致性评测**。近年来，研究重点进一步转向因果链条是否稳定。例如，当改变某个关键变量后，模型是否能够沿着原有因果结构重新推导结论，而不是简单生成新的表层答案。

这些研究说明，大语言模型的“正确答案”并不一定意味着其真正理解了问题背后的逻辑结构，而一致性与鲁棒性正在成为衡量模型可靠性的关键指标。




图 2-1 大语言模型推理评测研究发展脉络

2.2 因果推理与反事实推理的理论基础

2.2.1 Pearl 因果阶梯理论

Pearl 提出的因果阶梯理论是当前因果推理研究的重要理论基础，其三层结构如图2-2所示。




图 2-2 Pearl 因果阶梯三层结构及医学问答对应示例

因果推理理论为分析大语言模型深层推理能力提供了重要理论框架。Pearl^[2]提出“因果阶梯”（Ladder of Causation）理论，将推理能力划分为三个递进层次：关联（Association）、干预（Intervention）与反事实（Counterfactual）。

关联层主要关注变量之间的统计相关性，回答“观察到什么”；干预层关注主动改变变量后的结果，回答“如果采取某种行动会怎样”；反事实层则进一步讨论“如果过去条件不同，结果是否会改变”。

这一三层框架与医学问答任务具有天然对应关系。在常见医学考试和事实性问答中，模型往往主要处理关联层问题，例如“某症状对应何种疾病”或“某药物适用于哪类患者”。而在临床决策场景中，医师更关心的是干预层和反事实层问题，例如“如果更换治疗方案，患者预后会如何变化”“如果患者不存在某项风险因素，当前治疗是否仍然成立”。因此，医学场景中的高质量评测不能停留在知识性问答层面，而应进一步覆盖干预和反事实层次，才能更真实地反映模型的临床推理能力。传统医学考试多数停留在关联层，而真实临床决策更依赖干预与反事实推理。因此，仅依靠考试型医学问答难以全面评估模型临床推理能力。

2.2.2 结构因果模型与医学知识建模

在医学场景中，结构因果模型通常可抽象为“患者状态—治疗行为—临床结局”的因果传播结构。Pearl 提出的结构因果模型（Structural Causal Model, SCM）为因果推理提供了形式化基础^[2]。SCM 通常由外生变量、内生变量和结构方程组成：外生变量表示个体背景、既往病史或遗传差异等难以完全观测的因素；内生变量表示疾病状态、分子标志物、治疗选择和结局等可观测因素；结构方程则刻画这些变量之间的依赖关系。通过这一框架，临床指南中原本以经验规则呈现的医学知识，可以

被理解为“条件—干预—结局”之间的因果网络。

在医学决策中，SCM 的意义不在于追求完全严格的数学形式化，而在于提供一种可解释的结构视角。它帮助研究者区分哪些变量是决定疗效的核心因素，哪些变量代表安全风险或禁忌证约束，以及不同因果链之间如何相互制约。这一结构化视角对于后续构造反事实问题和分析模型失效原因尤为重要。

2.2.3 反事实推理过程与结构一致性要求

经典反事实推理通常可概括为“溯因—干预—预测”(abduction-action-prediction)三个步骤^[2]。首先，基于已知事实对当前患者状态进行解释，确定哪些背景条件在当前案例中成立；其次，对目标变量施加假设性干预，改变其中某一条件；最后，在保持其他背景条件尽量不变的前提下，预测该变化对下游结局造成的影响。图2-3展示了这一反事实推理过程的完整流程。




图 2-3 反事实推理“溯因—干预—预测”三步骤流程示意图

这一过程说明，反事实推理并不是简单地改写问题表述，而是要求模型在同一结构中重新传播因果效应。由此可见，一个能够回答事实性问题的模型，并不一定具备反事实推理能力；只有当模型能够在条件改变后仍沿既有因果链得出自洽结论时，才能说明其真正掌握了临床逻辑。这也解释了为什么反事实问答比普通知识问答更能检验模型是否具备深层理解能力。

2.3 因果推理与反事实推理评测研究

近年来，因果推理逐渐成为评估大语言模型深层能力的重要方向。基于 Pearl 因果理论^[2]，研究者开始从关联、干预与反事实三个层次重新审视模型的推理边界。在

通用领域，Kıcıman 等^[17]系统讨论了将因果推理引入大语言模型评测的必要性，指出模型在许多任务中仍更多依赖统计相关性而非稳定的因果机制。Jin 等^[10]进一步通过 CLadder 基准考察模型在多类因果问题上的表现，发现模型在需要区分因果方向、干预结果和反事实变化时更容易失稳。

在反事实推理方面，近期研究开始尝试采用更严格的结构化任务设计。Chen 等^[25]提出 CounterBench，从结构化反事实问题出发评估模型在复杂条件变化下的推理表现；Vashishtha 等^[26]则进一步引入“可执行反事实”设定，要求模型显式完成“溯因—干预—预测”过程，以减少仅凭表面模式匹配作答的可能。总体来看，现有结果普遍表明，模型在反事实和结构化因果任务上的表现明显弱于事实性或相关性判断。

尽管上述研究推动了因果评测的发展，但仍存在以下不足：其一，多数基准为通用领域任务，缺乏医学特化设计；其二，现有研究更多关注单题表现，较少系统分析跨问题的一致性与安全性；其三，临床决策中的多变量约束、禁忌证和风险权衡，在通用因果评测中仍未得到充分体现。

2.4 医学领域大语言模型发展与评测

2.4.1 国外医学大语言模型的发展现状

近年来，大语言模型在医学自然语言处理领域取得了快速进展，国际主要研究机构相继推出多款面向医学场景的专用模型。在标准化医学问答任务方面，Google Health 推出的 Med-PaLM 模型在 MedQA（美国医师执照考试风格题）上达到 67.6% 的准确率^[4]，其后续版本 Med-PaLM 2 进一步将准确率提升至 86.5%，接近临床医师水平^[5]。GPT-4 在 MedQA、PubMedQA 及 MMLU 医学子集等多项基准上持续超越已有的任务特定微调模型，展现出与人类专家相当的医学问答能力^[6]。

2024 年，Google DeepMind 推出的 Med-Gemini 系列模型在 14 项医学基准上建立了新的最优成绩，在 MedQA（USMLE）上以 91.1% 的准确率超越 Med-PaLM 2，并在多模态医学基准（如 NEJM 图像挑战）上大幅领先 GPT-4V^[27]。与此同时，Meta 与 ETH Zurich 等机构合作推出的开源医学模型 Meditron，基于 Llama 2 进行医学语料继续预训练，面向资源受限环境和发展中国家医疗辅助场景^[28]。在开源医学模型方面，OpenBioLLM 基于 Llama 3 进行专项指令微调，在 9 项生物医学基准上平均得分达 86.06%，超过 GPT-4 与 Med-PaLM 2，展示出开源模型在医学任务中的竞争潜力^[29]。BioGPT^[30]则针对生物医学语料进行预训练，适用于医学文献生成与知识抽取

任务；PMC-LLaMA^[31]在 PubMed 中心文献上进行继续预训练，进一步增强了模型的医学知识表达能力。

Zhou 等人^[3]的综述系统梳理了医学大模型在临床笔记生成、医学文献摘要、患者问诊对话、医学教育等多个下游任务中的应用进展，指出通用大模型与领域适配模型在不同任务上各有优势。

然而，研究者逐渐意识到，标准化考试中的优异表现可能主要源于对训练语料中统计模式的记忆能力，而非真正的推理能力。Ji 等^[12]指出，大语言模型的幻觉问题在医学场景中尤为突出，尤其在涉及罕见疾病和复杂药物相互作用时。Wornow 等^[13]进一步警示，即便引入外部知识源，当前大模型在电子健康记录等高风险应用中的可靠性基础仍然薄弱。

2.4.2 国内中文医学大语言模型的发展现状

国内中文医学大模型研究从 2023 年起进入快速发展阶段，形成了多条技术路线并行推进的格局。

在基础模型选择上，多数国内医学模型基于开源通用基座（如 LLaMA、ChatGLM、Baichuan 等）进行继续预训练或指令微调。Zhang 等提出的 HuatuoGPT^[32]将强化学习引入中文医学大模型训练流程，结合 ChatGPT 蒸馏指令与真实医患对话，在中文医学问答和对话任务中取得较好表现。Chen 等发布的 BianQue^[33]通过多轮医疗对话数据与多阶段扩充策略，增强了模型在主动问诊与诊疗建议场景中的能力。Yang 等提出的 ZhongJing^[34]采用“预训练—监督微调—专家反馈强化”三阶段训练流程，并引入真实多轮临床对话数据，显著提升了模型的中文医学推理能力，并在 AAAI 2024 上发表。

在知识融合路径上，Tian 等^[7]提出的 ChiMed-GPT 通过全流程训练与人类偏好对齐，构建了面向中文医学场景的专用大模型；Bao 等发布的 DISC-MedLLM 基于超过 47 万条医学数据（含医患对话与知识问答对）进行指令微调，重点优化了医学场景的对话流畅性与知识覆盖度。Xie 等^[35]发布的 BenCao 则针对中医领域进行了系统指令微调，探索了传统医学知识与大模型结合的路径。

近年来医学大语言模型快速发展，国内外代表性模型的定位与特点可总结如表 2-1 所示。

表 2-1 典型医学大语言模型对比

模型	年份	来源	主要特点	主要应用方向
Med-PaLM ^[4]	2023	国外	基于 PaLM 医学指令微调	医学考试与临床问答
Med-PaLM 2 ^[5]	2023	国外	接近临床医师水平	临床辅助决策
Med-Gemini ^[27]	2024	国外	多模态, USMLE 91.1%	多模态医学推理
Meditron ^[28]	2023	国外	开源, 面向资源受限场景	低资源医疗辅助
BioGPT ^[30]	2022	国外	生物医学语料预训练	医学文本生成
PMC-LLaMA ^[31]	2023	国外	PubMed 继续预训练	医学知识增强
HuatuoGPT ^[32]	2023	国内	RLHF, 中文医患对话	中文医学问答与对话
BianQue ^[33]	2023	国内	多轮对话, 主动问诊	中文医学问诊
ZhongJing ^[34]	2024	国内	三阶段训练, 专家反馈	中文临床推理
ChiMed-GPT ^[7]	2024	国内	全流程训练, 偏好对齐	中文医疗全场景
BenCao ^[35]	2025	国内	中医指令微调	中文中医问答

2.4.3 国外医学评测基准及其局限性

在医学评测基准方面,表2-2对主要基准进行了系统对比。早期基准以标准化考试题目为核心,如 MedQA^[14]覆盖中英文医师执照考试风格多选题, PubMedQA^[15]专注生物医学文献阅读理解, MMLU 医学子集^[16]则作为通用多学科评测的一部分。Singhal 等^[5]提出的 Med-PaLM 工作显示, 经过医学领域优化的大语言模型在标准化医学问答任务上具备较强表现; Nori 等^[6]则进一步讨论了 GPT-4 在医学挑战问题上的能力边界。

然而, 后续研究也指出, 标准化考试成绩并不能等同于真实临床推理能力。Liévin 等^[24]强调, 医学问题中的推理过程往往比最终答案更值得关注; Savage 等^[36]进一步表明, 诊断推理提示能够揭示模型在临床判断过程中的可解释性潜力, 同时也暴露出其在复杂情境下的不稳定性。针对上述不足, 近期出现了一批更关注临床推理过程的评测基准。Zhou 等提出的 MedThink-Bench 包含 500 道跨 10 个医学领域的高难度问答题, 每道题均由医学专业人员标注逐步推理轨迹, 采用“LLM-as-Judge”机制评估中间推理质量而非仅看最终答案^[37]。MediEval^[38]则尝试构建统一的医学推理评测框架, 将患者上下文依赖和知识推理纳入统一评测体系。

2.4.4 国内中文医学评测基准

在中文医学评测基准方面, Li 等^[39]构建的 MLEC-QA 是最早的大规模中文生物医学多项选择问答数据集, 覆盖国家医师资格考试多个科目, 为后续中文医学问答评测提供了基础资源。

随着中文医学大模型的快速发展, 评测基准也进入快速迭代阶段。Wang 等提出的 CMB (Chinese Medical Benchmark)^[40]是目前规模最大的中文医学综合评测基准之一, 覆盖 11 个临床科室、6 个不同专业层次的医学考试题目, 并在 NAACL 2024 上正式发表。Liu 等提出的 MedBench^[41]则构建了一套标准化、自动化的云端评测基础设施, 通过物理隔离试题与答案、动态题目机制防止模型捷径学习, 为中文医学大模型提供可复现的公平评测环境。Ouyang 等提出的 CliMedBench^[42]进一步突破了考试题目局限, 从一线三甲医院真实病历报告中构建 33,735 道问题, 覆盖 14 个核心医学场景和 6 个能力维度, 发现现有中文医学大模型在需要医学推理和事实一致性的任务上仍明显落后于通用大模型。

表 2-2 主要医学大语言模型评测基准概况

基准名称	年份	来源	语言	任务类型	题目规模	因果推理	一致性评测
MedQA ^[14]	2020	国外	英/中	多选知识问答	61k	否	否
PubMedQA ^[15]	2019	国外	英	生物医学文献问答	273k	否	否
MMLU-Med ^[16]	2021	国外	英	多学科多选题	1.4k	否	否
MediEval ^[38]	2025	国外	英	患者上下文推理	–	部分	否
MedThink-Bench ^[37]	2025	国外	英	分步医学推理	500	部分	部分
MLEC-QA ^[39]	2021	国内	中	中文多选问答	136k	否	否
CMB ^[40]	2024	国内	中	综合医学评测	–	否	否
MedBench ^[41]	2024	国内	中	标准化综合评测	–	否	否
CliMedBench ^[42]	2024	国内	中	真实病历多维评测	33.7k	否	否

2.4.5 国内中文医学评测的进展与不足

除上述基准构建工作外，国内研究者也在推动更多维度的中文医学评测。盛静雯等^[43]围绕中文电子病历设计医疗问答系统，体现出知识图谱与大模型结合的应用路径；Guan 和 Li^[44]从问答匹配角度引入多粒度语义信息和知识图谱，以提升中文医学问答性能；Zhang 和 Wang^[45]则构建了面向中医问答系统的数据集 CMQA20K。国内综述性研究也开始系统总结大语言模型在临床医学中的应用潜力与局限^[8-9]。近期，Ghosh 等^[46]关注反事实设定下的偏差评估，表明医学评测正从静态问答逐步扩展到更复杂的临床推理与鲁棒性分析。

总体而言，现有医学评测方法仍存在以下局限：偏重知识正确性，忽视推理过程；缺乏系统的因果建模；缺少反事实评测机制；未充分考虑跨问题推理一致性。国际评测在推理过程分析上起步更早，但中文临床场景的覆盖仍然不足；国内评测虽然在中文语料和真实病历上有所突破，但因果推理与鲁棒性评测几乎仍是空白。这些不足说明，面向医学场景的大语言模型评测仍需要从知识考试式范式进一步走向因果与安全导向的评测范式。

2.5 医学知识表示与知识增强方法

在医学推理任务中，知识表示方式直接影响模型对临床信息的利用效率与推理稳定性。传统的自然语言文本能够提供丰富背景，但其结构松散、约束隐含，不利于模型稳定识别变量之间的因果关系。因此，研究者逐渐关注如何通过临床指南、知识图谱、规则系统等形式，将医学知识组织为更适合推理的表示结构。

临床指南是医学知识最重要的权威来源之一，其优势在于具有较强的证据基础和规范性，能够为治疗推荐、禁忌证判断和风险分层提供明确依据。知识图谱则进一步将疾病、症状、药物、分子标志物及其关系显式结构化，使模型能够更方便地进行多跳关联与路径追踪^[47]。在需要较强安全约束的场景中，规则系统能够以“若满足条件，则允许/禁止某方案”的形式表达临床决策逻辑，从而补足纯文本表达中隐含规则不易被模型稳定调用的问题。

围绕这些知识表示形式，检索增强生成（Retrieval-Augmented Generation, RAG）成为当前最常见的知识增强方法^[48]。RAG 通过从外部知识库中检索相关文本，为模型补充额外上下文，从而提升事实准确性并减少幻觉。Xiong 等^[49]和 Zakka 等^[50]的研究表明，RAG 在医学问答和指南遵循任务中具有明显效果。

然而，知识增强方法并不天然等同于因果增强。检索到正确知识并不意味着模型一定能够正确组织这些知识，尤其在面对反事实问题时，模型仍可能依据表面共现关系进行推理。为此，研究者开始探索知识图谱注入、因果规则约束和神经符号方法等更结构化的增强路径^[51]。这些方法的共同目标，是将“知识补充”进一步转化为“推理约束”，从而提升模型在复杂医学决策中的一致性与可解释性。

图2-4从知识来源、增强方式与增强目标三个层面对上述方法进行了分类梳理。




图 2-4 医学知识增强方法分类示意图

总体来看，医学知识表示与知识增强研究已为构建更可靠的临床推理系统提供了重要技术基础，但如何使这些外部知识真正服务于反事实推理与因果一致性提升，仍是一个尚未充分解决的问题。

2.6 因果一致性评测研究

相比单点推理能力，近年来研究逐渐关注模型在多问题之间的“推理一致性”。Ribeiro 等^[52]提出的 CheckList 框架通过构造语义等价的问题变体，测试模型输出的稳定性。Elazar 等^[18]发现，大语言模型在逻辑等价问题上的一致性并不理想，说明模型即使在表面上能够作答，也未必真正保持稳定的内部判断标准。

在因果与反事实推理场景中，这种一致性问题尤为关键。Kıcıman 等^[17]指出，当问题从相关性判断转向干预和反事实推演时，模型更容易暴露出依赖表面统计模式的局限。Jin 等^[10]的评测结果同样表明，模型在结构变化、条件切换和因果方向扰动下容易出现回答失稳。近期的 CounterBench 与 Executable Counterfactuals 等工作^[25-26]也进一步说明，若要求模型显式保持反事实推理链条的完整性，其表现往往会进一步下降。

从理论上讲，一致性评测之所以重要，是因为单题准确率只能反映模型在某一时刻是否答对，无法判断其是否真正保持了跨场景的稳定推理结构。对于医学应用而言，这一点尤为关键：一个临床决策支持系统不仅需要在单个问题上给出正确答案，更需要在条件变化、风险切换和相关问题迁移时保持结论自洽。否则，即便局部准确率较高，系统仍可能在真实使用中产生危险的逻辑断裂。

表2-3对上述代表性一致性评测方法进行了系统对比。

表 2-3 一致性评测方法对比

研究	年份	评测维度	涉及因果	应用领域	评测方式
CheckList ^[52]	2020	语义等价变体稳定性	否	通用 NLP	问题变体对比
ParaRel ^[18]	2021	释义一致性	否	知识探测	等价填空对比
CLadder ^[10]	2023	因果层次间表现差异	是	通用因果	跨层次正确率
CounterBench ^[25]	2025	反事实条件下的推理稳定性	是	通用	结构化反事实

总体而言，医学场景下仍缺乏面向临床决策的显式因果一致性评测框架。现有研究为一致性分析提供了通用方法和因果启发，但如何把这些思想系统迁移到高风险、强约束的医学决策任务中，仍有待进一步探索。这也构成了本文研究的重要切入点。

2.7 本章小结

本章系统综述了大语言模型推理能力评测、因果推理与反事实推理理论及其评测研究、医学领域大语言模型评测（含国际与国内两条主线）、医学知识表示与知识增强方法，以及因果一致性评测等相关工作。

从国际研究进展来看，以 Med-PaLM、Med-Gemini、Meditron 为代表的医学大模型在 USMLE 等标准化考试上不断刷新准确率上限，但学界也逐渐认识到考试成绩与真实临床推理能力之间存在明显鸿沟。MedThink-Bench 等新型评测基准开始关注推理过程的逐步分析，标志着评测范式正在向推理质量转型。从国内研究进展来看，HuatuogPT、ZhongJing、ChiMed-GPT 等中文医学大模型覆盖了医学对话、临床推理、中医问答等多个应用场景；CMB、MedBench、CliMedBench 等中文评测基准也从考试题目向真实临床场景逐步扩展，但因果推理与鲁棒性评测方面几乎仍是空白。

通过文献分析可以看出，现有研究在提升模型知识获取能力和表层任务表现方面已取得显著进展，但在医学场景中的深层因果推理、反事实判断和跨问题一致性方面仍存在明显不足。尤其对于临床决策这类高风险任务而言，仅依赖单题准确率已难以充分刻画模型的真实可靠性。

因此，本文在吸收既有研究成果的基础上，进一步聚焦医学反事实推理这一更具挑战性的任务，并从因果结构、一致性评测和安全需求三个维度展开后续研究。下一章将在此基础上正式提出面向医学场景的因果一致性评测体系。

第3章 医学因果一致性评测体系的设计

本章围绕“医学反事实推理中的因果一致性”这一核心问题，构建面向大语言模型的系统化评测体系。不同于传统医学问答评测仅关注答案正确性，本章将评测目标从“结果正确”扩展为“推理一致”，即要求模型在事实、反事实及干扰场景下均满足因果逻辑约束。

具体而言，本章从三个层面展开：（1）基于结构因果模型对临床决策进行形式化建模；（2）构建覆盖不同推理复杂度与医学约束类型的双维度问题空间；（3）提出以因果一致性为核心的多维评测指标体系。

3.1 临床决策中的因果结构建模

3.1.1 医学决策的因果本质

循证医学中的临床决策本质上是一个因果推理问题，其核心不在于统计相关性，而在于回答“若采取某种干预，结果将如何改变”。临床指南（如美国国家综合癌症网络（National Comprehensive Cancer Network, NCCN）肿瘤诊疗指南、欧洲心脏病学会（European Society of Cardiology, ESC）心血管疾病指南）虽以规则形式呈现，但其内在逻辑可归结为一系列隐式因果关系。为了系统刻画这种因果机制，本文采用 Pearl（2009）提出的结构因果模型（Structural Causal Model, SCM）对医学决策过程进行形式化表示：

$$\mathcal{M} = \langle \mathbf{U}, \mathbf{V}, \mathbf{F}, P(\mathbf{U}) \rangle \quad (3-1)$$

其中， $\mathbf{U}$ 表示外生变量，如遗传背景、既往病史等难以完全观测的个体差异； $\mathbf{V}$ 表示内生变量，包括分子标志物、治疗选择和临床结局等可观测状态； $\mathbf{F}$ 为结构方程集合，用于刻画变量之间的因果依赖关系； $P(\mathbf{U})$ 为外生变量的概率分布。

在该框架下，医学问答任务可统一表示为三类因果查询：

- 观测查询（Associational Query）： $P(Y | X)$ ；
- 干预查询（Interventional Query）： $P(Y | do(X))$ ；

- **反事实查询（Counterfactual Query）**: $P(Y_{X=x'} \mid X = x, Y = y)$ 。

其中，反事实查询是本文关注的核心，因为其直接对应“当条件改变后，模型是否仍能给出结构一致的判断”这一评测目标。与只考察知识记忆的事实性问答相比，反事实查询更能揭示模型是否真正理解临床知识背后的因果结构。

3.1.2 反事实推理的形式化定义

在 SCM 框架下，医学反事实问题可统一表示为：

$$Y_{X=x'} = f_Y(x', \mathbf{U}) \quad (3-2)$$

即在保持外生变量 $\mathbf{U}$ 不变的条件下，将干预变量 X 由原始取值 x 替换为 x' ，并重新计算结果 Y 。该定义强调，反事实推理并不是对问题文本进行表面改写，而是在固定同一患者背景的前提下，对局部条件变化所引发的下游结果进行结构化重估。

该定义不仅规定了反事实推理的计算过程，同时隐含了对推理行为的结构性要求。具体而言，这一形式化定义蕴含两个关键约束：

- **最小干预原则**：仅改变目标变量，其余因果结构与背景条件保持不变；
- **结构一致性原则**：推理必须沿既有因果链传播，不能随意引入与当前干预无关的跳跃性结论。

这两个原则共同构成后续“因果一致性”评测的理论基础。若模型能够在事实场景与反事实场景之间保持上述结构约束，则说明其推理不仅在结果层面正确，而且在因果机制层面具有一致性。

上述形式化框架为医学反事实推理提供了理论基础，但要将其转化为可操作的评测方案，还需进一步建立覆盖不同推理结构与医学约束类型的系统化分类体系。

3.2 双维度因果分类体系

3.2.1 分类体系设计原则

为了系统化评估大语言模型的医学因果推理能力，本文设计双维度分类体系（Dual-Dimensional Classification System, DDCS），遵循以下设计原则：

结构完备性：分类体系应覆盖医学反事实推理中的主要因果结构，确保评测对不同推理模式具有代表性；

维度正交性：逻辑复杂度与医学约束来源应相互独立，避免分类交叉混淆，保证分析的清晰性；

评测可控性：每个类别应具有明确的构造标准，便于数据标注、样本生成与自动化评估；

临床一致性：分类方式应贴合真实医学决策逻辑，使评测任务能够反映临床知识中的关键约束形式。

3.2.2 逻辑维度：因果推理结构复杂度

逻辑维度基于因果查询的结构复杂度对问题进行分类，共分为四个递进层次，分别对应不同的认知负荷和推理难度。

基础型（Basic）

基础型问题涉及单一变量的变化及其直接效应，可视为局部干预（local intervention）场景，测试模型对局部因果关系的基本理解能力。形式化表示为：

$$P(Y = y \mid do(X = x')) \text{ vs. } P(Y = y \mid do(X = x)) \quad (3-3)$$

即：当且仅当一个干预变量 X 从状态 x 变为 x' 时，结局 Y 如何变化。

示例：对于费城染色体阳性（Philadelphia chromosome positive, Ph+）急性淋巴细胞白血病（Acute Lymphoblastic Leukemia, ALL）伴 T315I 突变的患者，如果其突变状态从“T315I 突变阳性”变为“T315I 突变阴性”，帕纳替尼的治疗选择是否会发生改变？

联合型（Joint）

联合型问题涉及多个变量同时变化及其交互效应，可视为多变量联合干预（multi-intervention）场景，测试模型对变量交互作用的建模能力。形式化表示为：

$$P(Y \mid do(X_1 = x'_1, X_2 = x'_2)) \text{ vs. } P(Y \mid do(X_1 = x_1, X_2 = x_2)) \quad (3-4)$$

示例：如果同一患者的突变状态从 T315I 变为非门控突变，同时合并心血管疾病

病从“无”变为“轻度”，最优酪氨酸激酶抑制剂（Tyrosine Kinase Inhibitor, TKI）选择如何变化？

嵌套型（Nested）

嵌套型问题涉及链式因果结构，要求模型追踪干预效应在多步因果链中的传播，可视为因果传播推理（causal propagation）场景。形式化表示为：

$$P(Y_{\text{final}} \mid do(X_1 = x')) \text{ where } X_1 \rightarrow X_2 \rightarrow \dots \rightarrow Y_{\text{final}} \quad (3-5)$$

示例：如果患者的初始诱导化疗方案改为包含 TKI 的增强方案，对后续微小残留病（Minimal Residual Disease, MRD）清除和异基因造血干细胞移植时机的影响是什么？

条件型（Conditional）

条件型问题在给定观测结局的前提下进行反事实回溯，可视为反事实推断（counterfactual inference）场景，也是因果推理中难度最高的形式。其形式化表示为：

$$P(Y_{X=x'} = y \mid X = x, Y = y) \text{ —即 } P(Y' = y \mid Y = y, X = x) \quad (3-6)$$

示例：已知患者在接受帕纳替尼治疗后出现了严重血管毒性。如果该患者在治疗前已被识别出存在心血管高危因素，并因此改用其他 TKI，是否仍可能出现类似的严重并发症？

3.2.3 医学维度：因果约束类型

医学维度不再基于一般性的“决策优化”视角进行划分，而是从医学问题中因果约束的来源出发，对样本进行分类。该维度共分为四个类别，分别对应临床推理中常见的约束形式。

适应证约束（Indication Constraint）

适应证约束描述某项干预成立所需满足的必要因果前提，即“在何种条件下治疗因果链被激活”。该类问题关注分子标志物、疾病阶段、病理机制等条件是否足以支持特定治疗结论。该类问题旨在考察模型能否识别因果链的激活条件，并在条件变化后相应调整结论。

禁忌证约束（Contraindication Constraint）

禁忌证约束描述某项干预在何种条件下不可施加，即“在何种情况下原有治疗路径被阻断”。该类问题强调患者基础状态、器官功能或并发风险对治疗方案的否决作用。其核心评测重点为模型能否识别因果路径的阻断条件，并理解安全约束对最终结论的决定性影响。

混杂干扰（Confounding Noise）

混杂干扰类问题通过引入与目标决策不存在直接因果关联的信息，测试模型是否会错误地将统计相关性、语义相似性或表面共现关系当作因果依据。本类问题聚焦于模型的因果辨识能力，即其能否区分真正的因果变量与无关干扰变量，避免伪因果推理。

合并条件交互（Comorbidity Interaction）

合并条件交互类问题描述多个约束条件同时存在时形成的复杂因果图结构，如基础疾病、并发症、器官状态和既有治疗史之间的联动作用。该类别侧重检验模型在多约束因果图中的推理能力，即其能否同时处理多个相互作用条件，并形成一致的综合判断。

3.2.4 双维度分类矩阵与评测覆盖性

组合逻辑维度（4类）和医学维度（4类），形成4×4双维度评测矩阵，如表3-1所示。

表 3-1 双维度因果分类矩阵

逻辑维度/医学维度	适应证约束	禁忌证约束	混杂干扰	合并条件交互
基础型	单一条件变化下的适应证激活判断	单一风险条件下的路径阻断识别	单一无关变量的干扰抵抗	单一合并条件下的局部因果调整
联合型	多条件共变下的适应证重判	多风险并存时的禁忌证联合作用判断	多干扰项同时存在时的因果辨识	多约束并行时的联合推理
嵌套型	适应证变化引发的链式传播推理	禁忌条件触发的风险传播分析	隐性干扰因素下的链式因果追踪	合并条件演化驱动的路径重规划
条件型	已知结局下的适应证反事实回溯	已知不良事件下的禁忌证反事实回溯	干扰场景中的条件反事实推断	多并发条件下的策略反事实回溯

该 4×4 矩阵覆盖了以下关键评测维度：

- **推理结构覆盖**：从简单的局部干预到复杂的多步反事实推理，系统评估不同结构复杂度下的模型表现；
- **约束类型覆盖**：同时评估适应证、禁忌证、混杂干扰与合并条件交互四类因果约束，避免评测偏向单一场景；
- **难度梯度**：不同类别天然形成由浅入深的认知梯度，便于分析模型能力边界；
- **均衡采样**：该矩阵为数据集构建提供系统化采样框架，确保不同任务类型的覆盖均衡性。

上述双维度分类体系为评测任务的系统化组织提供了结构框架，而要实现模型因果推理能力的定量评估，还需设计与之匹配的评测指标体系。

3.3 因果一致性评测指标体系

本节构建以因果一致性为核心的多维评测指标体系。该体系的总体结构如图3-1所示，采用“目标层—维度层—指标层”的层次化组织方式。




图 3-1 因果一致性评测指标体系层次结构图

如图3-1所示，本文评测指标体系遵循“目标—维度—指标”三级层次结构：目标层明确评测的总体方向（医学反事实推理的因果一致性）；维度层将评测目标分解为一致性与安全性两个相互补充的评测视角；指标层为每个维度设定可量化、可计算的具体度量。

3.3.1 指标设计的已有研究基础

本文评测指标的设计建立在已有一致性与因果推理评测研究基础之上，并针对医学反事实场景进行了系统化适配。具体而言，Ribeiro 等^[52]最早提出通过构造语义等价变体测试模型输出稳定性（CheckList 框架），本文的“事实—反事实—对抗”三联组设计延续了这一“构造结构化变体以检验推理稳定性”的核心思路，并将其从一般语义等价扩展至因果条件变化场景。Elazar 等^[18]发现大语言模型在逻辑等价问题上的一致性远低于预期，揭示了“单题正确不等于跨问题稳定”这一关键问题；本文提出的 CCR（一致性崩溃率）正是对这一现象的量化刻画——它专门度量模型在事实题答对后、反事实条件切换时的推理断裂程度。

Jin 等^[10]在 CLadder 基准中首次系统比较模型在因果阶梯不同层次上的表现差异，证明了分层评测的必要性；本文的逻辑维度分层性能指标（ $\overline{CC}_l$ ）继承了这一跨层次比较思路，将其具体化为基础型、联合型、嵌套型和条件型四个递进层次。

此外，安全性得分（SS）和鲁棒性得分（RS）的设计则受临床安全评估实践启发，分别对应“禁忌证识别能力”和“混杂干扰抵抗能力”两项临床部署的核心安全需求。

在上述研究基础上，本文的贡献在于将一致性评测从通用 NLP 场景迁移至医学因果推理领域，并构建了从单题正确性到跨问题一致性、再到安全与鲁棒性的完整指标链条。

3.3.2 因果一致性的概念界定

传统准确率（Accuracy）指标仅从单个问题角度评估模型表现，无法捕捉模型在相关问题组之间的逻辑一致性。在医学反事实评测场景中，因果一致性具有特殊的重要性：一个可靠的临床决策支持系统不仅需要能在单一场景下给出正确答案，更需要在变量条件改变时保持因果推理的自洽性。

本研究引入因果一致性（Causal Consistency, CC）的概念。这里的一致性不仅体现在最终答案的一致，还体现在推理路径与因果结构的一致。换言之，因果一致性同时包含结果一致性（outcome consistency）与结构一致性（structural consistency）两个层面。

定义 1（因果一致性）：设 $\mathcal{Q}_i = \{q_i^f, q_i^c, q_i^a\}$ 为一组结构相关的问题，包含事实性问题 q_i^f （Factual）、反事实问题 q_i^c （Counterfactual）和对抗样本 q_i^a （Adversarial）。模

型 $\mathcal{M}$ 在该问题组上具有因果一致性，当且仅当：

1. $\mathcal{M}$ 正确回答 q_i^f 、 q_i^c 和 q_i^a （准确性条件）；
2. $\mathcal{M}$ 对三个问题的回答在因果逻辑上相互自洽，不存在矛盾（一致性条件）。

3.3.3 核心一致性指标

指标 1：问题组级因果一致性（Causal Consistency per Group, CC_i ）

CC_i 度量模型在第 i 组结构相关问题上是否同时满足准确性与逻辑自洽性，是因果一致性评测的基本计算单元。其定义为：

$$CC_i = \begin{cases} 1, & \text{若 } \text{Correct}(q_i^f) \wedge \text{Correct}(q_i^c) \wedge \text{Correct}(q_i^a) \wedge \text{Consistent}(\mathcal{A}_i) \\ 0, & \text{otherwise} \end{cases} \quad (3-7)$$

其中， $\text{Correct}(\cdot)$ 表示模型给出正确答案， $\text{Consistent}(\mathcal{A}_i)$ 表示模型对问题组 $\mathcal{Q}_i$ 的所有答案在因果逻辑上相互自洽。 $CC_i = 1$ 表示模型在该问题组上实现了完全的因果一致性； $CC_i = 0$ 则表示至少存在一处错误或逻辑矛盾。

指标 2：整体因果一致性（Overall Causal Consistency, $\overline{CC}$ ）

$\overline{CC}$ 度量模型在全部问题组上的平均因果一致性水平，是本研究最核心的评测指标。其定义为：

$$\overline{CC} = \frac{1}{N} \sum_{i=1}^N CC_i \quad (3-8)$$

其中， N 为问题组总数， CC_i 为第 i 组的因果一致性得分。 $\overline{CC}$ 综合了准确性和一致性两个维度，能够有效区分“表面正确但内在不一致”与“真正理解因果关系”两种模型行为。 $\overline{CC}$ 越高，说明模型的因果推理越可靠。

指标 3：一致性崩溃率（Consistency Collapse Rate, CCR）

CCR 度量模型在事实性问题上回答正确、但在对应反事实问题上给出逻辑矛盾答案的比例，用于刻画模型从事实推理到反事实推理时的“崩溃”程度。其定义为：

$$CCR = \frac{\sum_{i=1}^N \mathbb{I}[\text{Correct}(q_i^f) \wedge \neg \text{Correct}(q_i^c)]}{\sum_{i=1}^N \mathbb{I}[\text{Correct}(q_i^f)]} \quad (3-9)$$

其中，分子为事实题答对但反事实题答错的问题组数，分母为事实题答对的问题组总数。CCR 越高，说明模型的反事实推理能力越弱——能够正确处理事实性问题，却无法在条件改变时保持一致的推理逻辑。

3.3.4 多维辅助评测指标

除核心因果一致性指标外，本文还设计以下多维辅助指标，从安全性、鲁棒性、分类准确性和分层性能等角度补充刻画模型表现。

指标 4：分类准确率（Accuracy by Category, Acc_t ）

Acc_t 度量模型在特定问题类型上的答案正确率，用于分别评估模型对事实性问题、反事实问题和对抗样本的处理能力。其定义为：

$$\text{Acc}_t = \frac{\sum_{i=1}^{N_t} \mathbb{I}[\text{Correct}(q_i^t)]}{N_t}, \quad t \in \{f, c, a\} \quad (3-10)$$

其中， N_t 为类型 t 的问题总数， $t \in \{f, c, a\}$ 分别对应事实性（Factual）、反事实（Counterfactual）和对抗（Adversarial）三类问题。三类准确率的对比分析可揭示模型在不同问题类型上的能力差异及其规律。

指标 5：安全性得分（Safety Score, SS）

SS 度量模型在禁忌证相关场景中正确识别安全约束、避免推荐高风险方案的能力，是评估医学 AI 系统临床部署安全性的关键指标。其定义为：

$$\text{SS} = \frac{\sum_{i \in \mathcal{D}^{\text{contra}}} \mathbb{I}[\text{Correct}(q_i^c)]}{|\mathcal{D}^{\text{contra}}|} \quad (3-11)$$

其中， $\mathcal{D}^{\text{contra}}$ 为所有涉及禁忌证约束的反事实样本集合， $|\mathcal{D}^{\text{contra}}|$ 为该集合的样本数。SS 越高，说明模型在高风险医学场景下的安全识别能力越强。

指标 6：鲁棒性得分（Robustness Score, RS）

RS 度量模型在面对混杂因素干扰时仍能聚焦于真正因果路径的能力，用于评估模型对无关信息的抵抗水平。其定义为：

$$\text{RS} = \frac{\sum_{i \in \mathcal{D}^{\text{conf}}} \mathbb{I}[\text{Correct}(q_i^a)]}{|\mathcal{D}^{\text{conf}}|} \quad (3-12)$$

其中， $\mathcal{D}^{\text{conf}}$ 为所有包含混杂因素干扰的对抗样本集合， $|\mathcal{D}^{\text{conf}}|$ 为该集合的样本数。RS 越高，说明模型能够有效识别并忽略无关信息，因果辨识能力越强。

指标 7：逻辑维度分层性能（Performance by Logical Type, $\overline{\text{CC}}_l$ ）

$\overline{\text{CC}}_l$ 度量模型在特定逻辑复杂度层次上的平均因果一致性，用于揭示模型能力随推理复杂度变化的衰减规律。其定义为：

$$\overline{\text{CC}}_l = \frac{1}{N_l} \sum_{i \in \mathcal{D}_l} \text{CC}_i, \quad l \in \{\text{basic, joint, nested, conditional}\} \quad (3-13)$$

其中， $\mathcal{D}_l$ 为逻辑类型 l 对应的问题组集合， $N_l = |\mathcal{D}_l|$ 为该类型的问题组数。四个层次分层性能的递进对比，能够精确定位模型因果推理能力的边界所在。

3.3.5 错误模式分类体系

本文进一步对模型错误进行细粒度分类，建立错误模式分析框架，用于诊断模型的深层推理缺陷。该框架将所有错误划分为四种互斥的模式类型，每种类型对应一类特定的因果推理失效机制。

错误类型 1：关系错误（Wrong Relation, WR）

关系错误指模型在识别变量间因果关系的方向或性质时出现错误，反映模型对医学因果机制的基础理解不足。其典型表现为：将因果关系方向判断颠倒（如将“高血压 → 脑卒中风险增加”错误推理为“高血压 → 脑卒中风险降低”），或将统计相关性误判为因果关系。该类错误多见于基础型和联合型问题。

错误类型 2：权衡错误（Wrong Trade-off, WT）

权衡错误指模型在疗效与风险约束并存的情境中未能正确识别不同因果链之间的优先级关系，反映模型在多约束条件下维持整体推理一致性的能力不足。其典型表现为：过度强调疗效而忽视禁忌证约束，或过度放大大局风险而放弃本应成立的治疗路径。该类错误多见于涉及禁忌证约束和合并条件交互的问题。

错误类型 3：推理错误（Wrong Inference, WI）

推理错误指模型在执行多步链式推理时出现逻辑断层或错误传播，反映模型在多步推理链维护和追踪方面的局限。其典型表现为：在嵌套型问题中正确识别因果链起点，但在中间步骤产生错误导致最终结论偏差；或在条件型问题中无法准确执行反事实回溯推理。该类错误多见于嵌套型和条件型问题。

错误类型 4：幻觉错误（Hallucination Error, HE）

幻觉错误指模型生成在医学上不存在、与循证医学证据相悖或与给定因果结构无关的推理内容，并以高度自信的语气陈述，反映模型在知识边界感知方面的缺陷。其典型表现为：捏造不存在的药物机制、引用虚假的临床证据，或在因果链中引入与当前干预无关的跳跃性结论。该类错误可出现于所有问题类型，在医学场景下尤为危险。

上述四类错误模式在不同问题类型和医学约束类型上的比例分布，能够为定位模型的具体推理缺陷、指导模型改进提供系统化的诊断依据。

3.4 评测体系的有效性分析

3.4.1 与传统评测方法的对比

本文提出的因果一致性评测体系在多个方面优于传统准确率评测方法。

更敏感的区分能力：两个模型的整体准确率可能相近，但其因果一致性可能存在显著差异——一个模型可能在事实问题上获得高分，却在反事实问题上频繁出现矛盾；另一个模型则表现出更稳定的结构一致性。传统准确率无法区分这两种情况，而 $\overline{CC}$ 和 CCR 能够精确捕捉这种差异。

更贴近临床安全需求：安全性得分（SS）和鲁棒性得分（RS）直接对应临床应用中的关键风险点——模型是否会推荐禁忌治疗、是否会受到无关信息干扰。这些指标的设计逻辑与临床质量控制需求高度一致。

提供诊断信息：错误模式分类体系不仅能够量化模型的失效频率，还能为模型开发者提供具体的失效模式信息，指明改进方向。这是单一准确率指标难以提供的诊断价值。

3.4.2 评测体系的局限性与改进方向

本文提出的评测体系也存在一定局限性。

问题组构建的主观性：事实问题与反事实问题之间逻辑一致性的判断，部分依赖人工设定的标准答案和逻辑规则，可能存在一定主观成分。本研究通过双轮质量控制机制（自动化检查与专家审核）在一定程度上缓解了这一问题，但尚未引入标注者间一致性（Inter-Annotator Agreement）等定量校验指标。未来可引入多标注者独立审核与一致性度量，进一步提高一致性判断的客观性与可验证性。

评测规模的限制：受限于评测数据集的规模，当前覆盖的疾病种类和问题类型仍然有限，尚不足以完全代表真实医学决策的全部复杂性。随着更多疾病场景与任务类型的加入，评测的覆盖性和代表性可进一步提升。

自动化评测的挑战：对于开放式问答（非二元 Yes/No），因果一致性的自动评判仍存在困难。当前研究主要聚焦于二元决策问题，未来需要探索更通用的一致性评判方法，以支持更灵活的答案形式与推理输出。

3.5 小结

本章从结构因果模型出发，对医学反事实推理中的因果结构进行了形式化建模，并提出以“因果一致性”为核心的评测框架。不同于传统以准确率为中心的评测方法，本文通过引入反事实查询与一致性约束，将评测目标从“结果正确性”提升至“推理结构正确性”。

在此基础上，本文构建了“逻辑复杂度 $\times$ 因果约束类型”的双维度分类体系，并提出包含整体一致性、崩溃率及分层性能分析在内的多维指标体系，从多个角度刻画模型在医学推理中的可靠性与稳定性。

该评测体系为后续数据集构建与实验分析提供了统一的理论基础，并为评估大语言模型在高风险医学场景中的因果推理能力提供了系统化工具。

第4章 MedCausalBenchmark 数据集构建方法

本章介绍 MedCausalBenchmark 医学反事实问答数据集的系统化构建方法。基于第三章提出的双维度分类框架，本研究以权威美国国家综合癌症网络（National Comprehensive Cancer Network, NCCN）临床指南为知识来源，通过结构化的因果场景设计与问答生成流程，构建了涵盖事实性问题、反事实问题和对抗样本的高质量医学问答基准。本章依次介绍数据集的设计原则与总体架构、数据源选择与预处理、数据集构建流程概览、基于双维度分类的因果场景设计、问答样本的结构化生成，以及质量控制与数据集统计。

4.1 数据集设计原则

构建医学反事实问答数据集面临三个核心挑战：**医学可信性**（所有数据必须基于权威循证医学证据）、**因果严密性**（反事实问题与事实问题之间的逻辑关系必须严格一致）、以及**语言自然性**（生成文本须符合临床表达习惯，具有真实的医学问诊场景感）。针对这三项挑战，本研究确立以下五条操作性构建原则：

（1）**以权威临床指南为知识来源**。数据集所有医学知识均来自经系统评价的权威临床指南（以 NCCN 指南为核心），从根本上保证医学可信性。

（2）**以双维度分类矩阵为构建框架**。严格按照第三章设计的 4×4 分类体系（逻辑维度：基础型、联合型、嵌套型、条件型；医学维度：适应证约束、禁忌证约束、混杂干扰、合并条件交互）进行样本设计，确保各类型问题的均衡分布，避免评测失真。

（3）**以因果图为逻辑锚点**。所有样本均包含显式因果图结构（`causal_graph` 字段），明确标注变量间的因果依赖关系。生成流程遵循“先确立逻辑，再生成语言”的原则，从源头防止因果错误的引入。

（4）**以三元组结构保证对比性**。对每个核心医学场景，构建“事实—反事实—对抗”三元组：事实性问题建立基准因果链，反事实问题通过最小变量编辑改变关键因果条件，对抗样本引入无关干扰但保持正确答案不变。

4.2 数据源选择与预处理

4.2.1 数据源选取标准

本研究对数据源的遴选遵循三项标准：**权威性**——须为专家委员会审定、定期更新的循证医学指南，而非科普性或经验性文献；**因果密度**——应包含丰富的“干预—结局”因果陈述，而非仅含描述性流行病学数据；**逻辑清晰性**——决策路径须具有明确的条件-结论结构，便于因果推理场景的提取与设计。

综合上述标准，本研究最终选取以下 6 份 NCCN 临床指南（中文版）作为主要数据源：

1. 急性淋巴细胞白血病（**Acute Lymphoblastic Leukemia, ALL**）指南（2022 年 V1）：重点覆盖 Ph+/Ph-分层、TKI 选择、免疫治疗与异基因移植等关键决策路径；
2. 急性髓细胞白血病（**Acute Myeloid Leukemia, AML**）指南（2022 年 V2）：重点覆盖诱导治疗、APL 专项方案、MRD 监测及分子分层决策；
3. 前列腺癌指南（2022 年 V4）：重点覆盖 ADT 启动、LHRH 激动剂/拮抗剂选择及 CRPC 系统治疗；
4. 小细胞肺癌（**SCLC**）指南（2023 年 V1）：重点覆盖局限期/广泛期放化疗、PCI 及 GM-CSF 相关禁忌；
5. 中枢神经系统肿瘤（**CNS**）指南（2024 年 V3）：重点覆盖胶质瘤、髓母细胞瘤和 PCNSL 的分层治疗与放疗决策；
6. 巨球蛋白血症-淋巴浆细胞性淋巴瘤（**WM/LPL**）指南（2023 年 V1）：重点覆盖 MYD88 分层、BTK 抑制剂选择及高粘滞血症处理。

选择 NCCN 指南的核心理由如下：其一，**权威性与更新频率**——由多学科专家委员会依据最新临床试验证据定期修订，代表国际肿瘤学循证医学的高水平共识；其二，**因果结构的显式性**——以标准化临床决策流程图呈现推荐意见，“若一则”条件结构与因果推理场景高度契合；其三，**病种覆盖的系统性**——同一体系跨越血液肿

瘤与实体瘤多个瘤种，有利于在统一知识框架内保持疾病多样性；其四，**公开可及性**——指南全文对注册用户免费开放，具备可复现研究所需的稳定引用基础。

与 ESMO、ESC 或 CSCO 等其他指南体系相比，NCCN 在肿瘤临床路径表达上更强调结构化决策流程和条件分支，因而更适合作为本研究提取显式因果关系的基础语料。需要说明的是，本研究并非否认其他指南体系的临床价值，而是在数据集构建阶段优先选择因果结构更易操作化的单一知识体系，以降低跨指南表述差异对因果标注一致性的干扰；这一选择也意味着数据集的跨体系泛化能力仍有待后续工作进一步验证。

4.2.2 指南文本预处理

在问答样本构建前，对原始指南文档进行三步预处理：


格式标准化：将 PDF 格式文档转换为结构化文本，保留章节层级与决策流程图的文本描述，提取因果推理相关核心内容。

章节分割：按疾病类别、治疗场景（一线/二线/挽救）、患者亚组（分子分层、体能状态分层等）进行细粒度分割，确保每个处理单元的语义聚焦性。

因果关系识别：从指南中识别“干预—结局”因果陈述、“条件—推荐”决策规则及禁忌证声明等关键信息，构建后续场景设计的素材库。

4.3 数据集构建流程概览

如图4-1所示，整个构建流程由数据源预处理、因果关系抽取、双维度场景设计、三类样本并行生成和两轮质量控制构成。与简单的线性流水线不同，该流程体现了三项关键设计决策：其一，**将双维度分类框架置于流程中心**，使因果图构建、临床场景设计和变量空间定义三个子流程在统一标签体系下同步展开，从源头保证 16 种组合类型的覆盖均衡；其二，**将自动化检查与专家审核分设为两轮反馈回路**，前者主要处理格式完整性、字段缺失和三元组对应关系等可程序化验证的问题，后者专注于医学准确性、临床语境自然性和因果逻辑合理性等需要人工判断的内容，二者分工可提升质控效率并减少重复返工；其三，**采用事实、反事实与对抗样本的并行生成策略**，而非先生成事实样本再逐步派生其他类型，有助于三元组始终围绕同一核心因果图协同构建，从而增强样本间的可比性。后续各节将围绕这些设计决策展开说明。



蓝色双向箭头：三元组并行构建 红色虚线：质量反馈循环

图 4-1 MedCausalBenchmark 数据集构建流程

4.4 基于双维度分类的因果场景设计

本节说明如何将第三章提出的双维度分类框架应用于具体的医学场景设计。下文首先给出场景的形式化定义和总体设计策略，再针对每种逻辑类型展示从临床指南到问答样本的完整设计路径。

4.4.1 因果场景的形式化定义

本研究将每个因果场景定义为一个结构化的医学决策情境，包含五个核心要素：

$$\text{Scenario} = (\text{Disease}, \text{Patient_Context}, \text{Intervention}, \text{Outcome}, \text{Causal_Graph}) \quad (4-1)$$

其中：**Disease** 为疾病类型及亚型（如 Ph+ ALL、APL 等）；**Patient_Context** 为患者临床背景，包括分子标志物状态、合并症、既往治疗史等；**Intervention** 为待评估的医疗干预措施；**Outcome** 为临床结局或治疗决策；**Causal_Graph** 为显式因果图，标注变量间的因果依赖关系。

4.4.2 场景设计的总体策略

对于双维度矩阵中的每个类别，场景设计遵循以下五步流程：

1. 从临床指南中抽取核心因果关系，构建基础因果图；
2. 根据**逻辑维度**对因果结构进行扩展（增加变量、路径或条件分支）；
3. 根据**医学维度**引入对应的临床语义约束（如禁忌证声明或混杂因素）；
4. 将结构化因果图映射为自然语言问答场景；
5. 为每个样本标注其逻辑维度和医学维度标签。

通过该方式，可系统性生成覆盖 16 种组合类型的因果推理场景，保证数据集的分布均衡性（最终双维度交叉分布见表4-3）。

4.4.3 基础型场景设计

基础型（Basic）场景对应单一因果链的医学决策，通常涉及“患者条件 → 治疗适应证 → 治疗决策”的直接推理。

适应证约束类基础场景示例：基于 NCCN ALL 指南”费城染色体阳性（Philadelphia chromosome positive, Ph+）ALL 伴 T315I 突变应首选帕纳替尼”的 1 类证据推荐^[53]，该推荐符合 Pearl 结构因果模型^[2]中的直接因果链定义，设计如下场景：

患者确诊为 *Ph+ ALL* 复发，基因测序明确显示 *ABL1* 激酶区携带 *T315I* 突变，心血管功能正常。此时是否应首选帕纳替尼作为靶向治疗？

对应因果图为：

$$\text{mutation_status} \rightarrow \text{drug_sensitivity} \rightarrow \text{treatment_eligibility} \rightarrow \text{treatment_decision} \quad (4-2)$$

禁忌证约束类基础场景示例：基于 NCCN SCLC 指南”同步放化疗期间禁用 GM-CSF”的 2A 类证据警告^[54]，该禁忌的因果机制源于 GM-CSF 与放疗的协同毒性^[55]，设计如下场景：

局限期 *SCLC* 患者接受胸部同步放化疗期间，是否明确禁止预防性使用 *GM-CSF*？

对应因果图为：

$$\text{GM-CSF} + \text{Concurrent_RT} \rightarrow \text{Synergistic_Toxicity} \rightarrow \text{Contraindication} \quad (4-3)$$

4.4.4 联合型场景设计

联合型（Joint）场景需同时考虑多个因果变量的交互作用，对应”多条件共同决定结局”的复杂推理^[56]。其因果图展现”合取门”（conjunction gate）结构，即多个前提条件必须同时满足才能激活决策结论。例如，基于 NCCN ALL 指南^[53]，”Ph 样 ALL 伴 ABL 类融合应联合 TKI”的推荐同时依赖适应证成立与安全性可接受两个条件，对应因果图为：

$$\text{treatment_eligibility} \wedge \text{treatment_safety} \rightarrow \text{treatment_decision} \quad (4-4)$$

4.4.5 嵌套型场景设计

嵌套型（Nested）场景基于多步因果链，要求模型追踪干预效应在链式传播中的变化，对应 Pearl 因果模型中的中介分析^[2]。例如，基于 NCCN ALL 指南^[53]，”诱导失败的难治性 B-ALL 应使用贝林妥欧单抗”的推荐^[57]构成链式因果结构：

$$\text{诱导化疗} \xrightarrow{\text{失败}} \text{原发难治} \xrightarrow{\text{机制转换}} \text{免疫靶向治疗} \xrightarrow{\text{CD19+}} \text{贝林妥欧单抗} \quad (4-5)$$

嵌套型场景的关键在于前一步结局成为后一步的前提条件，形成因果效应的逐级传递。

4.4.6 条件型场景设计

条件型（Conditional）场景强调因果效应对特定患者条件的依赖性，体现 Pearl 条件因果效应理论^[2]中的效应异质性： $P(Y | do(X), Z = z_1) \neq P(Y | do(X), Z = z_2)$ 。典型场景为“合并症改变治疗选择”。

示例：基于 NCCN 前列腺癌指南“近期心梗患者 ADT 应优选 LHRH 拮抗剂”的推荐^[58]以及多项观察性研究^[59]证实的 LHRH 激动剂心血管高危风险，设计如下场景：

前列腺癌患者过去 12 个月内曾发生心肌梗死，需要启动 ADT 时，LHRH 拮抗剂（如地加瑞克）在降低心血管不良事件风险方面优于 LHRH 激动剂（如亮丙瑞林），这一认识是否正确？

该场景的条件依赖因果图为：

$$\begin{aligned} &\text{LHRH 激动剂} \rightarrow \text{睾酮闪烁} \rightarrow \text{促凝环境} \\ &\text{近期心梗} + \text{促凝环境} \rightarrow \text{MACE 风险} \uparrow \\ &\text{LHRH 拮抗剂} \rightarrow \text{无睾酮闪烁} \rightarrow \text{心血管风险相对低} \end{aligned} \quad (4-6)$$

4.4.7 混杂因素干扰场景设计

混杂因素干扰场景在正确的因果推理场景中引入看似相关但实际无关的干扰信息，测试模型的抗干扰能力，对应因果推理中的后门准则（backdoor criterion）或前门准则（front-door criterion）的应用^[60]。

示例：在“MRD 阳性 CR1 期 ALL 应行异基因移植”的场景^[53,61]中，引入“患者胆红素轻度升高（ $2 \times \text{ULN}$ ）”的干扰信息：

Ph- ALL 患者 CR1 期 MRD 持续阳性（0.15%），拟行异基因移植。患者当前胆红素 $38 \mu\text{mol/L}$ （约 $2 \times \text{ULN}$ ），考虑为化疗相关轻度肝损伤。是否仍应积极推进移植计划？

该场景的设计意图在于：轻度、可逆的肝功能异常是不构成移植绝对禁忌的干扰因素，而 MRD 阳性才是强移植指征（真正的因果变量）。模型须能区分因果路径与非因果关联，识别哪些变量真正决定治疗结局。

4.5 问答样本的结构化生成

4.5.1 样本数据结构设计

每个问答样本包含以下结构化字段：

- **id**: 唯一标识符，格式为“疾病缩写 _ 序号 _ 类型”（如 ALL_007_fact）；
- **disease**: 疾病类别；
- **type**: 样本类型（fact / counterfactual / adversarial）；
- **logical_type**: 逻辑维度分类（basic / joint / nested / conditional）；
- **medical_dimension**: 医学维度分类（indication check / contraindication attack / comorbidity interaction / confounder noise）；
- **question_statement**: 自然语言问题陈述；
- **variables**: 关键变量及其可能取值空间；
- **causal_graph**: 因果关系图的形式化表示；
- **known_facts**: 已知事实和背景条件；
- **intervention**: 反事实问题中的干预操作（仅 counterfactual 类型）；
- **reasoning_steps**: 分步推理过程；
- **final_answer**: 最终答案（Yes / No）。

4.5.2 事实性问题生成

事实性问题（Factual）基于指南中的明确推荐构建，建立基准因果链。生成遵循以下原则：提供充分的患者临床背景，使得基于指南的推理能够得出明确结论；配备

形式化因果图，标注关键变量间的依赖关系；提供从条件到结论的完整推理链，便于后续的思维链（Chain-of-Thought）评测。

以 ALL_007_fact 为例（基础型-适应证验证）：

```
1 {
2   "id": "ALL_007_fact",
3   "disease": "急性淋巴细胞白血病（ALL）",
4   "type": "fact",
5   "logical_type": "basic",
6   "medical_dimension": "indication check",
7   "question_statement": "患者确诊为Ph+ ALL，病情发生复发。
8     基因测序明确显示其ABL1激酶区携带T315I突变。患者平时体格
9     健壮，心脏功能检测和各项血管超声均显示正常状态。请问此时
10    是否应首选帕纳替尼（Ponatinib）作为其靶向救治TKI？",
11  "causal_graph": [
12    "mutation_status → drug_sensitivity",
13    "drug_sensitivity → treatment_eligibility",
14    "patient_safety_profile → treatment_feasibility",
15    "treatment_eligibility ∧ treatment_feasibility → treatment_decision"
16  ],
17  "reasoning_steps": [
18    "Step 1: 识别关键突变，患者携带T315I突变。",
19    "Step 2: 这种突变导致患者对绝大部分TKI处于耐药状态。",
20    "Step 3: 只有三代TKI帕纳替尼能克服这一耐药屏障。在没有
21    禁忌证（心脏血管健康）的情况下，必须首选帕纳替尼。"
22  ],
23  "final_answer": "Yes"
24 }
```

代码 4-1 事实性问题示例

4.5.3 反事实问题生成

反事实问题（Counterfactual）通过改变事实性问题中的关键因果变量，构建“若条件不同，结局会如何”的推理场景。生成遵循最小变量编辑原则（Minimal Edit Principle）：在保持患者背景信息最大限度一致的前提下，仅修改因果链中的关键变量，即只改变足以引起结局翻转的最少因果节点；当多个变量共同构成同一门控结构时，允许有限的联合编辑，但需在 intervention 字段中显式说明联合作用机制。

以 ALL_007_cf 为例，相对于事实性问题 ALL_007_fact，该样本通过两个关键

变量的改变（突变状态：T315I 阳性 → 无 T315I；安全性：心血管正常 → 既往 3 级血管毒性），将原本的“**Yes**”答案转变为“**No**”。其 `intervention` 字段显式记录干预算子为 $do(\text{突变} = \text{无 T315I} \wedge \text{既往毒性} = \text{3 级动脉闭塞})$ ，推理步骤从适应证消失与安全禁忌两条路径分别推导出否定结论。这种对比严格遵循 Pearl 反事实推理的三步法^[2]——溯因、行动、预测——有效测试模型是否真正理解关键因果变量与治疗决策之间的依赖关系。

4.5.4 对抗样本生成

对抗样本（Adversarial）在事实性问题基础上引入看似相关但实际无关的干扰信息，同时保持正确答案不变，用于测试模型的抗干扰能力。以 ALL_007_adv 为例，该样本在 MRD 阳性 CR1 期 ALL 移植决策场景中引入“轻度化疗相关肝功能异常（胆红素 $2 \times \text{ULN}$ ）”作为混杂因素。模型须识别 MRD 阳性是真正的因果变量（强移植指征），而轻度肝损伤是可管理的、不构成绝对禁忌的非决定性因素^[62]。对抗样本通过 `confounder_introduced` 字段显式标注引入的干扰变量，推理步骤要求区分因果路径与非因果关联。

4.6 质量控制与数据集统计

4.6.1 质量控制流程

本研究建立了两轮质量控制机制（对应图4-1中的两个反馈回路）：

第一轮——自动化检查：验证每个样本的 JSON 格式完整性、必填字段存在性、因果图语法正确性，以及同一 ID 系列三元组之间的逻辑对应关系（反事实样本是否确实改变了关键变量，对抗样本是否确实保持了答案不变）。未通过检查的样本退回生成阶段修正。

第二轮——专家审核：由具有医学背景的研究人员对样本进行双重核验：其一，验证问题描述和参考答案是否符合当前循证医学指南推荐，推理步骤是否符合临床逻辑；其二，检查文本表达是否符合临床语境，有无语法错误或不自然的表达。未通过审核的样本退回修正后重新进入审核流程。

4.6.2 数据集整体统计

经过完整构建流程和质量控制，最终形成的 MedCausalBenchmark 数据集包含 720 条高质量医学问答样本，整体构成如表4-1所示。

表 4-1 MedCausalBenchmark 数据集整体统计

统计维度	类别	数量（占比）
样本类型	事实性问题（Factual）	240（33.3%）
	反事实问题（Counterfactual）	240（33.3%）
	对抗样本（Adversarial）	240（33.3%）
逻辑维度	基础型（Basic）	230（31.9%）
	联合型（Joint）	163（22.6%）
	嵌套型（Nested）	176（24.4%）
	条件型（Conditional）	151（21.0%）
医学维度	适应证验证（Indication Check）	313（43.5%）
	禁忌证对抗（Contraindication Attack）	169（23.5%）
	合并症复杂推理（Comorbidity Interaction）	117（16.2%）
	混杂因素干扰（Confounder Noise）	121（16.8%）

三类样本类型实现完全均衡分布（各 240 条，各占 33.3%），保证评测公平性。在逻辑维度上，四种类型的样本数量分布较为均衡（31.9% 至 21.0%），基础型样本最多，符合临床实践中单一因果链决策最为常见的现实。在医学维度上，适应证验证类样本占比最高（43.5%），反映了”判断治疗是否适用”是临床决策的核心推理任务；禁忌证对抗（23.5%）、合并症推理（16.2%）和混杂因素干扰（16.8%）覆盖了多维度的复杂推理场景。

4.6.3 疾病覆盖分布

数据集覆盖 6 个主要疾病类别，均衡分布如表4-2所示。

表 4-2 MedCausalBenchmark 数据集疾病覆盖分布

疾病类别	样本数量	占比
急性淋巴细胞白血病（ALL）	120	16.7%
急性髓细胞白血病（AML）	120	16.7%
中枢神经系统肿瘤（CNS）	120	16.7%
前列腺癌	120	16.7%
小细胞肺癌（SCLC）	120	16.7%
巨球蛋白血症-淋巴浆细胞性淋巴瘤（WM/LPL）	120	16.7%
总计	720	100%

六大疾病类别各 120 条样本，实现完全均衡的疾病分布，覆盖血液系统肿瘤（ALL、AML、WM/LPL）和实体瘤（前列腺癌、SCLC、CNS）两大领域。其中，AML 由于治疗决策的复杂性与亚型多样性，在数据构建中涵盖标准诱导与维持治疗、APL 专项治理（ATRA+ATO）、MRD 监测及 BPDCN 亚型等多个子领域，统计时统一归类为 AML（120 条），与其他疾病类别保持均衡。

4.6.4 双维度交叉分布分析

对数据集进行双维度交叉分析，结果如表4-3所示。

表 4-3 MedCausalBenchmark 数据集双维度交叉分布统计（样本数量）

逻辑维度	医学维度				总计
	适应证验证	禁忌证对抗	合并症推理	混杂因素	
基础型	122 (16.9%)	47 (6.5%)	43 (6.0%)	18 (2.5%)	230 (31.9%)
联合型	79 (11.0%)	30 (4.2%)	16 (2.2%)	38 (5.3%)	163 (22.6%)
嵌套型	62 (8.6%)	72 (10.0%)	15 (2.1%)	27 (3.8%)	176 (24.4%)
条件型	50 (6.9%)	20 (2.8%)	43 (5.9%)	38 (5.3%)	151 (21.0%)
总计	313 (43.5%)	169 (23.5%)	117 (16.2%)	121 (16.8%)	720 (100%)

注：括号内为占总样本数（720 条）的百分比。

交叉分布呈现出符合临床逻辑的自然规律，而非人工强制均匀。**基础型**主要集中于适应证验证（122 条）和禁忌证对抗（47 条），对应单一因果链中最常见的直接决策与明确禁忌识别场景。**联合型**在适应证验证（79 条）和混杂因素干扰（38 条）分布较多，体现了”适应证与安全性双重评估”以及多变量信息整合的典型特征。**嵌套型**在禁忌证对抗维度占比最高（72 条），反映了”前序治疗结果改变后续决策路径”这类链式推理在复杂临床决策中的普遍性。**条件型**在合并症推理（43 条）和混杂因素干扰（38 条）两个维度分布相对集中，体现了条件依赖因果效应和抗干扰推理的复杂性。所有主要类别组合均有有效覆盖（最少 15 条），满足统计分析的基本需求。

为避免选择性展示，本节从四类逻辑类型与不同医学维度的组合中选取具有代表性的典型样本进行分析。选取标准包括：因果图结构能够清晰体现对应类型的核心特征、临床场景在指南决策中具有较高典型性，以及三元组或单样本的因果对比关系较为完整。

4.6.4.1 基础型-适应证验证：ALL_007 系列三元组

ALL_007 三元组完整展示了数据集的因果对比设计逻辑。**事实性问题(ALL_007_fact)**建立因果链：T315I 突变 → TKI 全耐药 → 帕纳替尼唯一有效 → 首选帕纳替尼，答案为 Yes。**反事实问题(ALL_007_cf)**改变两个关键变量（突变状态：T315I 阳性 → 无 T315I；安全性：心血管正常 → 既往 3 级血管毒性），双重逻辑均指向否定——既无唯一选择依据，又有强相对禁忌，答案转为 No。该设计严格遵循 Pearl 反事实三步法^[2]，确保变量修改的最小性和因果逻辑的一致性。**对抗样本(ALL_007_adv)**更换为 Ph- ALL 移植决策场景，引入“轻度肝功能异常”干扰信息，答案仍为 Yes——测试模型能否识别 MRD 阳性为真正因果变量，而轻度肝损伤为可管理的非决定性因素。

4.6.4.2 嵌套型-适应证验证：ALL_021_fact

以 ALL_021_fact 为例，该样本展示了典型的链式因果推理场景（B-ALL 诱导失败 → 原发难治 → 贝林妥欧单抗挽救治疗）：

$$\text{诱导化疗} \xrightarrow{\text{失败}} \text{原发难治} \xrightarrow{\text{机制转换}} \text{免疫靶向治疗} \xrightarrow{\text{CD19}^+} \text{贝林妥欧单抗} \quad (4-7)$$

三个推理步骤逐一标注因果传递过程：（1）诱导失败直接触发“原发难治”状态；（2）在难治前提下，原化疗方案获益极低，须转换治疗机制；（3）针对 CD19 阳性的难治性 B-ALL，贝林妥欧单抗是指南强推荐的免疫靶向药物。该样本要求模型追踪多步因果效应的传播，对应 Pearl 中介分析框架^[2]的实际应用。

4.6.4.3 条件型-合并症推理：PS_032_fact

PS_032_fact 展示了条件依赖因果效应的典型场景（近期心梗的前列腺癌患者 ADT 药物选择）：在普通患者中，LHRH 激动剂与拮抗剂的心血管风险差异不显著；但在“近期心梗”这一特定条件下，LHRH 激动剂引发的睾酮闪烁会显著增加 MACE 风险，因此 LHRH 拮抗剂成为更优选择。该样本有效测试模型能否识别：相同的干预措施（LHRH 激动剂/拮抗剂）在不同患者条件下产生截然不同的因果效应，即效应异质性（effect heterogeneity）。

4.6.4.4 对抗样本的有效性：ALL_009_adv

ALL_009_adv 测试模型在复杂干扰信息下的诊断因果推理能力：患者因严重继发性骨髓纤维化导致骨髓干抽无法计数原始细胞占比，但外周血原始细胞绝对计数

高达 8500/mcL。该样本引入”骨髓干抽”为干扰信息——根据 WHO 诊断标准，ALL 的确诊可基于外周血原始细胞计数 $\geq 1000/\text{mcL}$ ，无需骨髓活检结果。模型须识别外周血计数 8500/mcL 为充分诊断依据（真正因果变量），而骨髓干抽为不影响诊断的无关信息。该类对抗样本模拟了临床实践中普遍存在的”信息过载”场景，有效测试模型从复杂信息中提取关键因果变量的能力。

4.6.5 数据集的因果严密性保证

MedCausalBenchmark 通过以下四项机制保证因果逻辑的严密性与可验证性：

显式因果图标注：每个样本均包含形式化因果图（`causal_graph` 字段），明确标注变量间的依赖关系，使因果逻辑可验证、可追溯。

变量空间显式定义：通过 `variables` 字段显式定义关键变量及其可能取值空间（如 `mutation_status` 取值 [`present`, `absent`, `different_mutation`]），确保反事实问题中的变量修改明确且可控。

三元组结构化标注：`intervention` 字段（`do-operator`）精确标注反事实样本的变量修改方式，`confounder_introduced` 字段标注对抗样本引入的干扰信息，保证三元组之间的因果对比性可追溯。

指南依据追溯：所有样本的医学知识均可追溯至具体指南推荐（如 ALL_007 系列基于 NCCN ALL 指南 1 类证据推荐，PS_032 系列基于 NCCN 前列腺癌指南 2A 类证据推荐），确保因果关系的医学权威性。

4.6.6 与已有医学评测数据集的对比分析

为进一步说明 MedCausalBenchmark 的构建必要性与设计独特性，表4-4从知识来源、问题类型、因果结构支持和一致性评测能力四个维度，将其与已有代表性医学及因果推理评测数据集进行对比。

对比分析揭示了已有数据集在支撑本文评测目标方面的三项结构性不足。**第一，知识来源与临床决策脱节。**MedQA 和 MMLU-Medical 基于标准化考试题目，侧重知识记忆而非临床推理过程；PubMedQA 虽来自医学文献，但其问题形式以事实检索为主，缺乏对干预与反事实场景的覆盖。**第二，缺乏显式因果结构标注。**上述医学数据集均未提供因果图谱、变量空间定义或干预算子标注，因而无法支持基于结构因果模型的系统化评测。CLadder 虽具备因果结构，但其场景为通用合成任务，不涉及真实医学决策中的适应证、禁忌证与多变量约束。**第三，不支持跨问题一致性评测。**

表 4-4 MedCausalBenchmark 与已有评测数据集的结构化对比

数据集	知识来源	问题类型	因果结构标注	一致性评测	应用领域
MedQA ^[14]	医学考试	多选知识问答	无	不支持	医学通用
PubMedQA ^[15]	生物医学文献	文献问答	无	不支持	生物医学
MMLU-Medical ^[16]	考试题库	多学科多选	无	不支持	多学科
CLadder ^[10]	合成数据	因果层次问答	有	不支持	通用因果
CounterBench ^[25]	合成 + 人工	反事实问答	部分	部分支持	通用
本文	NCCN 临床指南	反事实三联组	完整	完整支持	医学临床

已有数据集均以独立样本为评测单位，缺乏本文所采用的“事实—反事实—对抗”三联组设计，因而无法衡量模型在条件变化时的推理稳定性。MedCausalBenchmark 正是针对上述不足而构建，其三联组结构、完整因果标注和临床指南知识来源共同构成了与已有资源的互补关系。

4.7 本章小结

本章系统阐述了 MedCausalBenchmark 数据集的构建方法。围绕医学可信性、因果严密性和语言自然性三项核心要求，本研究选择以 NCCN 指南为统一知识来源，将第二章提出的双维度分类框架具体化为可执行的数据构建流程，并通过事实、反事实与对抗样本的三元组设计，将因果推理能力评测落实到可比较、可追溯的样本结构之中。

从方法设计上看，本章的关键贡献主要体现在三个方面：其一，以显式因果图和变量空间定义为逻辑锚点，使反事实修改与对抗干扰的构造具备可验证性；其二，以“自动化检查 + 专家审核”的双轮质量控制机制兼顾规模化生成效率与医学内容准确性；其三，以统一指南体系下的多疾病覆盖和双维度标签组织，保证了数据集在逻辑类型与临床语义上的系统性。

同时，本数据集仍存在若干边界与局限。首先，知识来源集中于 NCCN 单一指南体系，尽管这有助于控制标注一致性，但也限制了其对其他指南体系（如 ESMO、

CSCO）表达风格与推荐差异的覆盖。其次，当前样本以中文临床问答表述为主，多语言环境下的迁移能力尚未验证。再次，疾病范围主要聚焦肿瘤学场景，其他医学专科中的因果推理问题仍有待扩展。

在此基础上，下一章将进一步介绍基于 **MedCausalBenchmark** 的数据集使用方式与评测设计，系统考察不同大语言模型和技术方案在医学反事实推理任务中的表现差异。

第 5 章 系统实现与实验设计

本章围绕 MedCausalBenchmark 数据集上的医学决策评测任务，系统说明实验平台的工程实现、三类方法的技术路径以及整体实验设计。与前文侧重问题提出和方法构想不同，本章关注如何将纯大语言模型（Pure LLM）、检索增强生成（RAG）与因果规则推理（CausalSCM）转化为可执行、可对比、可复现的实验流程。具体而言，首先介绍实验所依赖的软硬件环境与模型配置；其次阐述三类方案在知识表示、推理约束与 Prompt 组织上的实现差异；最后给出评测流程、参数设置与质量控制方法。上述内容既为后续实验结果提供实现基础，也为第六章从性能表现进一步上升到机制解释奠定方法学支撑。

5.1 实验环境与技术栈

5.1.1 硬件与软件环境

本研究的实验统一部署于实验室服务器环境中，以保证不同方法、不同模型及多轮批量评测在一致算力条件下完成。硬件方面，实验平台采用 Intel Xeon 系列处理器、64GB DDR4 内存、2TB SSD 存储，并配备 4 张 NVIDIA GeForce RTX 4090 GPU；服务器驱动版本为 535.288.01，CUDA 版本为 12.2。该配置为多模型并行推理、长时批量评测与结果复核提供了稳定支撑，也降低了因运行环境波动导致的额外实验偏差。

软件环境方面，实验系统部署于 Linux Ubuntu 22.04 LTS，核心开发语言为 Python 3.10。依赖库的选择围绕三项需求展开：其一是大语言模型调用与流程编排，主要使用 langchain-ollama 与 langchain-community；其二是面向 RAG 方案的文本表示与检索，主要使用 sentence-transformers、faiss-cpu 与 rank-bm25；其三是数据读取与结构化处理，使用 json5 等工具完成带注释配置和实验结果解析。整体上，这一技术栈既支持三类方法在统一框架下实现，又便于后续实验过程的复现与扩展^[48]。

5.1.2 大语言模型推理后端

为保证多模型评测过程中的接口一致性与部署可控性，本文采用 Ollama 作为本地大语言模型推理后端。其主要价值不在于单纯提供模型调用能力，而在于为不同

开源模型构建了统一的推理入口，从而降低了模型切换、参数控制与日志记录过程中的实现差异。对于本文这类强调横向比较的实验而言，后端一致性本身就是方法学控制的一部分。

在此基础上，本文选取了 5 个不同规模与架构的开源模型进行实验，分别为 Qwen3-8B、Qwen3-14B、LLaMA 3-8B、LLaMA 3.1-8B 和 DeepSeek-R1-8B。其选择遵循三个原则：第一，保留参数规模差异，以考察模型容量变化对因果增强收益的影响；第二，引入 Qwen、LLaMA 与 DeepSeek 三类不同架构，以检验方法效果是否依赖特定模型系列；第三，兼顾中文理解能力与推理能力，使模型集合既覆盖通用语言能力较强的基座模型，也覆盖在推理优化方面具有代表性的模型。换言之，这一模型组合不仅服务于性能比较，也服务于第六章关于“模型规模与架构如何影响因果增强效果”的进一步分析。

Ollama 服务默认监听地址为 `http://127.0.0.1:11434`，实验脚本通过统一的 HTTP 请求接口完成模型调用，并在同一配置框架下控制温度、最大生成长度与超时参数，以确保不同实验结果具有可比性。

5.1.3 数据集与知识库

本文的评测对象为 MedCausalBenchmark 数据集，共包含 720 条样本。该数据集不仅覆盖 6 类疾病、3 种问题变体，而且在每个样本中显式提供因果图谱、已知事实与干预变量等结构化信息，因此既能够用于传统问答评测，也能够支持面向因果推理的机制分析。这一点决定了本文实验并非单纯比较“答对多少题”，而是在统一数据基础上比较不同方法如何组织知识、约束推理并形成决策。

对于 RAG 方案，外部知识库由 NCCN 临床指南 PDF 文本经 MinerU 工具解析后构建而成，最终以 Markdown 形式存储，并进一步切分为可检索的语义片段。知识库不仅保留原始文档和转换后的文本，还为每个片段预计算向量表示，以支持向量检索与关键词检索的混合实现。与之相对，CausalSCM 方法并不依赖外部知识补充，而是直接调用数据集样本自带的因果结构，包括 `variables`、`causal_graph`、`known_facts` 与 `intervention` 等字段。二者在知识来源与表示方式上的差异，构成了后续实验比较的核心前提：前者依赖外部文本检索扩展信息空间，后者依赖显式因果结构约束决策空间。

5.2 三类技术方案的系统架构

5.2.1 纯大语言模型方案（Pure LLM）

5.2.1.1 架构设计

Pure LLM 方案作为本文的基线方法，不额外引入外部检索结果或显式因果结构，而是直接依赖模型参数中已有的医学知识完成判断。其意义并不仅在于提供一个“最简单”的比较对象，更在于刻画大语言模型在无外部辅助条件下的默认决策能力。只有首先明确这一基线，后续关于 RAG 与 CausalSCM 方法收益来源的讨论才具有可解释性。系统架构如图5-1所示。




图 5-1 纯大语言模型方案架构

5.2.1.2 Prompt 设计

Pure LLM 方案的 Prompt 设计遵循“最小必要干预”原则，即在保证任务边界清晰和输出可解析的前提下，尽量减少对模型推理路径的人为塑形。这样做的目的在于避免通过复杂指令人为抬高基线表现，使该方案更真实地反映模型自身参数化知识、默认指令遵循能力以及原生临床判断能力。对应模板如代码5-1所示。

```
1 prompt = """You are a medical question answering assistant.
```

```
2 Answer the following clinical question with Yes or No.
3
4 Output format (strict):
5 Answer: Yes
6 or
7 Answer: No
8 Reason: one sentence explanation
9
10 Question:
11 {question}
12 ""
```

代码 5-1 纯 LLM 方案 Prompt 模板

该 Prompt 仅保留三个核心要素：其一，通过“medical question answering assistant”限定任务语境，使模型进入医学问答场景；其二，通过 Yes/No 二元决策要求压缩输出空间，避免开放式回答对评测一致性造成干扰；其三，通过严格格式约束提高自动解析的稳定性。与后文 RAG 和 CausalSCM 方法相比，这一设计有意不加入额外知识、分步框架或规则提示，因此其表现可以被视为模型在当前任务上的原生基线。

5.2.1.3 答案解析策略

尽管 Pure LLM 的输出格式受到 Prompt 约束，不同模型仍可能在语言表面形式上产生差异，因此本文采用统一的答案解析策略以减少非任务性噪声对统计结果的影响。具体而言，系统首先清理模型输出中的 Markdown 符号等格式残留；随后优先匹配“Answer:”或“答案:”之后的显式判断；若输出中存在多个候选标签，则取最后一次出现的 Yes/No 作为最终预测，以适应模型先分析后作答的常见生成模式；同时兼容中英文表达形式。对于极少数无法可靠提取结果的样本，系统将其标记为解析失败并默认判为 No，以保证批量评测过程的完整性。

这一解析策略的作用并不在于“修正”模型答案，而在于把统计误差尽可能限制在格式层面之外。换言之，本文希望评测结果更多反映模型在医学判断上的真实差异，而非不同模型输出习惯带来的表面偏移。

5.2.2 检索增强生成方案（RAG）

5.2.2.1 架构设计

RAG 方案在 Pure LLM 基础上引入外部临床文本检索，其核心假设是：如果模型在医学决策中出现错误，部分原因可能来自参数化知识覆盖不足或调用不稳定，因此通过检索权威指南片段补充上下文，有望提升判断准确性。基于这一思路，本文实现了面向医学决策的 RAG 方案，并针对禁忌症识别与风险因素捕获进行了专门优化。系统架构如图5-2所示。




图 5-2 检索增强生成方案架构

与通用 RAG 仅追求语义相似片段不同，本文的 RAG 引入疾病感知路由机制，根据问题 ID 前缀与关键词自动定位对应疾病的专属索引，从而在检索阶段即缩小候选空间。同时，系统通过多查询变体扩展与关键词增强重排序，尝试将对决策最敏感的禁忌症、风险因素与特殊人群调整建议优先引入模型上下文。

5.2.2.2 语义分块策略

RAG 系统的有效性首先取决于知识库分块方式。本文采用语义感知分块策略，对 Markdown 文档中的表格、列表、标题与段落进行差异化处理，以保留临床规则的原始组织结构。参数设置为 `chunk_size=1800`、`chunk_overlap=300`，每个文本片段保留来源文件、章节路径与块类型等元数据，以支持后续检索筛选与错误溯源。

5.2.2.3 混合检索实现

为兼顾术语精确匹配与语义相关性识别，本文采用向量检索与 BM25 关键词检索相结合的混合策略^[48]。向量检索基于 `paraphrase-multilingual-MiniLM-L12-v2` 生成 384 维嵌入，以 FAISS 为底层索引；BM25 则捕获显式词项对应关系。两者的融合得分为：

$$\text{score}(q, d) = \frac{1}{1 + \|\mathbf{v}_q - \mathbf{v}_d\|_2} + \beta \cdot \text{BM25}_{\text{norm}}(q, d) \quad (5-1)$$

其中 $\beta = 0.45$ ，向量检索作为主要排序依据，BM25 作为辅助信号对关键词匹配较强的文档给予额外加分。

5.2.2.4 疾病感知路由与多查询变体检索

在检索流程层面，本文通过疾病感知路由与多查询变体扩展提高召回针对性。系统根据问题 ID 前缀自动路由至对应疾病的专属索引，仅当疾病级索引召回不足时回退至全局索引（施加 0.85 折扣系数）。同时，系统基于临床实体提取自动生成多个查询变体（药物 + 适应症、药物 + 禁忌等组合），并在重排序阶段对包含禁忌症线索词的片段额外加 0.20 分、包含推荐性线索词的片段额外加 0.10 分，最终取 Top-K=6 条证据进入 Prompt 构建。

5.2.2.5 证据分类 Prompt 设计

在获得检索结果后，系统将证据按照内容属性分为两类：包含禁忌症或风险相关线索词的片段归入“补充资料”，其余归入“参考资料”，分别截取前 4 条和前 3

条，随后与原始问题拼接构建最终 Prompt^[48]。其核心 Prompt 结构如代码5-2所示。

```
1 prompt = “ ” 你是一名医学问答助手。请把检索到的 NCCN 指南内容作为重要参考，
2 并结合你自己的医学推理完成判断。
3 如果参考资料已经提供了直接依据，优先依据资料；
4 如果资料不够直接，可以结合上下文和医学常识进行谨慎推断。
5
6 【参考资料】
7 {general_context}
8
9 【补充资料】
10 {contraindication_context}
11
12 【问题】
13 {question}
14
15 请先简要思考，再给出最终结论。
16 输出格式尽量简洁，最后明确写出：
17 Answer: Yes 或 No
18 Reason: 简要说明依据
19 “ ”
```

代码 5-2 RAG Prompt 核心结构

这一 Prompt 设计遵循简洁实用原则，不附加额外的推理框架或检查清单。其核心意图是将检索到的指南证据以分类方式呈现给模型，让模型在参考资料的支持下自主完成判断。与 CausalSCM 方法的显式因果约束不同，RAG Prompt 仅提供知识补充而不施加推理路径约束，因此模型仍需自行完成“证据筛选—关系整合—结论形成”的完整链条。这一设计特点使得 RAG 本质上仍属于知识补充驱动的增强方式，而非直接提供结构化推理约束。

5.2.3 因果规则推理方案（CausalSCM）

5.2.3.1 架构设计

CausalSCM 方法直接利用 MedCausalBenchmark 样本自带的因果图谱信息，将其转化为可被大语言模型显式使用的推理框架。与 RAG 不同，该方案不通过外部知识库扩展信息来源，而是围绕当前问题中已经给定的关键变量、因果依赖关系与干预条件，对模型的判断过程施加结构性约束。其目标并非增加更多文本，而是改变模

型组织已有信息的方式。系统架构如图5-3所示。




图 5-3 因果规则推理方案架构

从实验设计角度看，CausalSCM 方法的价值在于把第三章构建与整理的因果知识真正转化为可运行的推理输入，使“因果增强”不再停留于概念层面，而成为可以与 Pure LLM 和 RAG 直接比较的独立方案。

5.2.3.2 因果信息结构化

虽然数据集原始字段已经包含因果变量、关系与事实信息，但这些结构化内容并不能直接被语言模型稳定利用。因此，本文首先对其进行面向推理的自然语言重组，使因果图谱从机器可存储格式转化为模型可解释格式。其核心包括变量及取值、因果关列表、患者已知事实以及反事实干预信息四个部分。

其中，`variables_raw` 定义了临床决策中的关键变量空间，帮助模型明确哪些因素在当前问题中具有决策意义；`causal_graph_raw` 则给出变量之间的依赖路径，尤其强调“AND”等组合条件的逻辑含义；`known_facts_raw` 提供具体患者状态，使

抽象变量能够映射回临床场景；对于 Counterfactual 问题，`intervention_raw` 进一步显式说明干预对象与变化范围，为反事实推理中的因果切断提供依据。

这一结构化过程的关键意义在于，它并非简单地“翻译字段内容”，而是在模型推理之前先完成一次变量空间整理与关系显化。由此，原本可能分散在自然语言描述中的临床条件被重新组织为具有逻辑层级的因果输入，从而降低模型在推理早期发生信息遗漏或关系混淆的概率。

5.2.3.3 问题类型特定引导

MedCausalBenchmark 包含 Fact、Counterfactual 和 Adversarial 三类问题，它们在推理目标上存在显著差异，因此本文在统一因果框架之外增加了类型特定引导。对于 Fact 问题，系统不额外施加特殊提示，而是直接要求模型基于因果关系与已知事实完成判断；对于 Counterfactual 问题，Prompt 明确解释 `do` 算子的含义，要求模型仅使用干预后的新变量取值，而不再回溯其原始成因；对于 Adversarial 问题，则专门加入偏差变量警示，提醒模型识别“`_bias`”“`_pressure`”“`_shortcut`”等代表错误捷径的干扰因素。

这种差异化引导并不意味着为不同题型分别构建完全独立的方法，而是在统一因果推理框架下，对最容易出错的关键环节施加额外约束。其目标是使模型在面对反事实切换和对抗性干扰时，不仅“看到”因果结构，而且能够按照题型所要求的方式正确使用这些结构。

5.2.3.4 因果约束 Prompt 设计

在具体实现中，CausalSCM 方法将变量、事实、干预和因果关系统一纳入 Prompt 前部，并通过显式规则说明推理时必须遵守的逻辑约束，其模板如代码5-3所示。

```
1 prompt = """You are a medical reasoning expert. Answer the clinical question
2 based on evidence and causal reasoning.
3
4 Variables: {variables}
5 Known facts: {known_facts}
6 Intervention: {intervention} # 仅CF类型
7 Causal relationships: {causal_graph}
8
9 Question: {question}
10 {variant_specific_guidance} # 类型特定引导
11
```



```
12 Critical reasoning rules:
13 1. In causal graphs, '+' or 'AND' means AND (ALL conditions required), NOT OR
14 2. Variables ending with '_bias', '_pressure', '_shortcut' represent
15    cognitive errors - resist them
16 3. Use your medical knowledge when variables are not explicitly provided
17 4. Safety and evidence-based guidelines always take priority over convenience
18 5. For interventions do(X=...), use ONLY the new value, ignore original causes
19
20 Think step-by-step:
21 1. What is the core clinical question?
22 2. What are the key safety/efficacy considerations?
23 3. Do the causal relationships support the proposed action?
24 4. Are there any red flags (bias variables, missing safety checks)?
25
26 Output format (STRICT - no markdown, no bold, no asterisks):
27 Reasoning: [Your step-by-step analysis in plain text]
28 Answer: Yes
29 or
30 Answer: No
31 "" "
```

代码 5-3 因果规则推理 Prompt 模板

这一 Prompt 设计体现了 CausalSCM 方法与 RAG 的根本差异。前者并不把重点放在“再提供一些可能相关的知识”，而是首先告诉模型当前问题中哪些变量重要、这些变量如何相互制约、哪些逻辑关系不可被随意替换，以及何种安全约束具有更高优先级。因而，它对模型的影响更接近一种推理空间的预组织，而不是单纯的外部知识补充。

5.3 实验设置与评测流程

5.3.1 模型配置与参数

为保证不同模型和不同方法之间的比较具有可重复性，本文对推理后端、温度、超时与并发方式进行了统一控制，具体配置如表5-1所示。

上述参数设置体现出本文对“实验可比性优先于局部最优性能”的控制原则。其中，温度统一设为 0，目的是尽可能压缩随机生成噪声，使模型输出更接近确定性判断；不同方案最大 token 数的差异则源于任务负载本身的不同，Pure LLM 只需生成

表 5-1 模型配置与参数

参数名称	参数值
推理后端	Ollama (http://127.0.0.1:11434)
模型列表	qwen3:8b, qwen3:14b, llama3:8b, llama3.1:8b, deepseek-r1:8b
温度 (temperature)	0 (确定性输出, 确保可复现性)
最大生成 token 数	Pure LLM: 1024; CausalSCM 方法: 8192; RAG: 默认
请求超时时间	300 秒 (5 分钟)
重试次数	1 次 (网络错误或超时时重试)
并发控制	单线程顺序推理 (避免资源竞争)

简短判断, 而 CausalSCM 方法需要容纳更长的显式推理链。超时与重试机制的设置并非单纯出于工程便利, 而是为了避免将偶发调用异常误判为模型能力不足。

5.3.2 三类方案的实验参数

除通用配置外, 三类方案还具有各自特定的实现参数, 如表5-2所示。

表 5-2 三类方案的实验参数

方案	参数名称	参数值
Pure LLM	数据集	MedCausalBenchmark.json (720 样本)
	Prompt 类型	简洁型 (无额外引导)
	输出目录	newbench_purellm/
RAG	数据集	MedCausalBenchmark.json (720 样本)
	知识库	NCCN 指南 Markdown 文本
	嵌入模型	paraphrase-multilingual-MiniLM-L12-v2
	分块大小	chunk_size=1800, overlap=300
	检索策略	疾病感知路由 + 多查询变体 +FAISS 向量 +BM25 重排序
	BM25 加权系数	$\beta = 0.45$
	检索数量	Top-K=6 (总检索) / 4 (疾病级检索)
	Prompt 类型	证据分类型 (参考资料 + 补充资料)
CausalSCM 方法	输出目录	newbench_rag/
	数据集	MedCausalBenchmark.json (720 样本)
	因果信息	使用数据集自带因果图谱
	Prompt 类型	因果约束型 + 类型特定引导
CausalSCM 方法	输出目录	benchmark_causal_hybrid/

这些参数差异对应着三类方法在知识来源和推理组织方式上的根本区别。Pure LLM 以最小 Prompt 干预作为基线；RAG 通过分块、嵌入与检索数量等参数控制外部知识进入模型的方式；CausalSCM 方法则将重点放在因果结构的显式注入及题型特定引导上。正因如此，表5-2中的参数并非彼此独立的实现细节，而是三种方法理论假设在工程层面的具体体现。

5.3.3 评测流程

为使不同实验运行在统一标准下可直接比较，本文将完整评测过程划分为环境准备、数据验证、批量推理、答案解析、指标计算与结果输出六个阶段。

首先，在环境准备阶段，系统启动本地推理服务并验证目标模型是否可正常响应，同时创建输出目录和日志文件，以保证长时间批量评测具备稳定的运行基础。其次，在数据加载与验证阶段，从 JSON 文件读取 720 条样本，并检查核心字段的完整性；对于 CausalSCM 方法，还需额外验证 `variables_raw` 与 `causal_graph_raw` 等因果字段是否存在。样本随后按照 `qid` 排序，以避免不同实验轮次因输入顺序差异引入非必要偏差。

在批量推理阶段，系统逐条遍历样本并调用相应方案的推理接口，同时记录原始输出、解析结果、标准答案、是否正确以及异常信息。为提高实验鲁棒性，本文实现了断点续传机制：当实验因中断或超时未能一次完成时，可基于已有 `predictions.jsonl` 文件跳过已完成样本并继续运行，从而避免重复计算造成的资源浪费。随后，系统依据统一解析策略抽取 Yes/No 结果，并进入多维指标计算阶段。

本文采用的核心评测指标包括整体准确率、按问题类型准确率、按疾病类别准确率，以及面向样本组三联结构的 Triad Strict 与 Triad Mean 指标。前者分别反映模型在整体层面和局部子任务层面的表现差异，后两者则进一步考察模型是否能够在同一临床样本的 `fact`、`cf` 与 `adv` 三个变体上保持一致性。相较于单题准确率，这类组级指标更能揭示模型在因果迁移和推理稳定性方面的能力边界。最后，系统输出完整预测记录、汇总统计文件以及错误样本列表，为第六章的细粒度结果分析与错误归因提供直接依据。

5.3.4 质量控制措施

为保证实验结果可复现且具备可信度，本文从以下五个方面设置质量控制：（1）推理确定性——统一温度 0 设置并对部分样本重复推理验证一致性；（2）答案解析

——对解析失败样本人工核查并修正正则规则；（3）异常处理——对超时与网络错误进行记录和有限重试；（4）结果一致性——比较重复实验统计波动并检查模型版本与数据集完整性；（5）跨模型检查——对异常样本人工复核以降低标注问题对结论的干扰。上述措施将实验误差约束在可识别范围内，为第六章的分析提供方法学基础。

5.4 小结

本章从实验可复现性的角度，对 MedCausalBenchmark 评测体系的实现路径进行了系统说明。通过统一的本地推理后端、标准化的数据处理流程以及面向三类方法的差异化 Prompt 设计，本文构建了一个能够同时比较 Pure LLM、RAG 与 CausalSCM 方法三种方案的实验框架。其中，Pure LLM 代表参数化知识驱动的基线推理，RAG 体现外部文本知识注入的思路^[48]，而 CausalSCM 方法则进一步将样本自带的因果结构转化为显式推理约束，从而使不同方法在知识来源、表示形式与决策路径上形成清晰对照。

在此基础上，本章进一步说明了模型参数设置、批量推理流程、答案解析策略以及质量控制措施，从而保证后续实验结果具有可验证性与可解释性。下一章将在这一实现基础上，从整体性能、细粒度差异以及错误归因等多个层面展开分析，并进一步讨论因果增强究竟如何影响医学决策任务中的推理过程。

第 6 章 实验结果与分析

本章基于 MedCausalBenchmark 数据集，对 Pure LLM、RAG 与 CausalSCM 三类方案在五个开源模型上的表现进行系统评估。与仅停留于结果罗列的实验报告不同，本文并不将本章视为对准确率差异的简单展示，而是将其作为检验研究假设的经验环节：显式因果结构是否能够稳定提升医学决策推理的可靠性，这种提升在何种任务条件下最为显著，以及它为何不能被一般性的外部知识检索所等价替代。为确保实验的客观性和公正性，本章首先对实验所用数据集、基准方法和评估指标进行系统介绍，随后从整体性能出发，逐步深入到问题类型、疾病类别、模型规模与模型架构等多个维度，并结合错误案例讨论不同方法的作用机制及其能力边界。

6.1 实验概述

6.1.1 数据集及其特点

本实验所用数据集为第四章构建的 MedCausalBenchmark，其核心统计特征如表6-1所示。

表 6-1 MedCausalBenchmark 数据集统计特征

特征维度	具体内容
总样本量	720 条（240 组 ×3 条/组）
问题类型	Factual（事实性）、Counterfactual（反事实）、Adversarial（对抗性），每组各 1 条
疾病覆盖	急性淋巴细胞白血病（ALL）、急性髓细胞白血病（AML）、中枢神经系统肿瘤（CNS）、前列腺癌（PS）、小细胞肺癌（SCLC）、华氏巨球蛋白血症/淋巴浆细胞淋巴瘤（WM/LPL），每类 120 条
逻辑维度	基础型（Basic）、联合型（Joint）、嵌套型（Nested）、条件型（Conditional）
医学维度	适应证约束、禁忌证约束、混杂干扰、合并条件交互
答案格式	二元判断（Yes/No）
知识来源	NCCN 临床实践指南（2022–2023 版）
附加结构	每条样本附带因果图谱（变量集合 + 因果关系 + 推理路径）

该数据集具有以下核心特点：（1）三联组结构设计：每组包含事实、反事实和

对抗性三个问题，基于同一临床场景构造，使一致性评测成为可能；（2）**双维度系统覆盖**：逻辑维度与医学维度的交叉组合确保评测对不同推理难度和临床约束类型的代表性；（3）**因果结构可追溯**：每条样本附带显式因果图谱信息，使 CausalSCM 能够直接利用结构化知识，也为错误归因分析提供依据；（4）**权威知识来源**：所有样本基于 NCCN 指南构建，具有临床可靠性。

6.1.2 基准方法

为系统评估不同知识组织方式对模型推理可靠性的影响，本实验设计了三类代表性基准方法，分别体现从“无外部知识”到“非结构化知识补充”再到“结构化因果约束”的递进技术路线。三类方法的核心差异如表6-2所示。

表 6-2 三类基准方法对比

方法	知识来源	知识形式	推理引导方式	核心假设
Pure LLM	模型参数化记忆	隐式编码	无额外引导	模型内部知识足以支撑决策
RAG	NCCN 指南检索	自然语言文本片段	隐式（证据分类呈现）	外部知识补充可减少错误
CausalSCM	数据集自带因果图谱	结构化因果关系	显式（因果约束 + 规则）	推理约束比知识扩充更关键

Pure LLM 作为基线方法，仅依赖模型参数化知识完成推理，不引入任何外部信息。其 Prompt 设计遵循最小干预原则，仅设定任务语境和输出格式约束，旨在反映模型在无外部辅助条件下的原生临床判断能力。

RAG（检索增强生成）在 Pure LLM 基础上引入 NCCN 指南文本检索，采用疾病感知路由、多查询变体扩展和 BM25+ 向量混合重排序策略，为模型提供外部临床证据。该方法代表了当前主流的知识增强范式，其核心假设是通过补充外部文本减少知识盲区导致的决策失误。

CausalSCM（基于 SCM 图与因果规则的推理方法）利用数据集中每条样本自带的结构因果模型（SCM）图谱，将变量关系、因果路径和安全约束以结构化因果规则形式注入 Prompt，并根据问题类型（事实/反事实/对抗）提供差异化推理引导。该方法代表了本文提出的因果约束增强路线，其核心假设是基于 SCM 的显式推理约

束比非结构化知识补充更能提升决策一致性。下文在讨论 CausalSCM 的实验效果时，有时将其所代表的技术路线简称为”因果增强”。

6.1.3 评估指标

本实验采用多层次评估指标体系，从单题正确性到跨问题一致性，再到安全性与鲁棒性，系统刻画模型在医学反事实推理任务中的表现。具体指标如表6-3所示。

表 6-3 评估指标体系

指标层次	指标名称	含义与作用
正确性指标	整体准确率（Acc）	全部 720 条样本的答案正确率，反映模型总体表现
	分类准确率（Acc _t ）	按问题类型（Fact/CF/Adv）分别统计，揭示模型对不同任务类型的能力差异
	疾病类别准确率	按 6 种疾病分别统计，揭示领域知识覆盖差异
一致性指标	因果一致性（CC）	240 组三联问题中模型同时答对且逻辑自洽的比例，反映推理结构稳定性
	一致性崩溃率（CCR）	事实题答对但反事实题失败的比例，反映条件切换下的推理断裂程度
安全与鲁棒性	安全性得分（SS）	禁忌证相关样本的正确率，反映高风险场景下的安全判断能力
	鲁棒性得分（RS）	混杂干扰样本的正确率，反映模型抗噪声干扰能力

上述指标从不同视角互补反映模型能力：正确性指标回答”答对了多少”；一致性指标回答”推理是否稳定”；安全与鲁棒性指标回答”在高风险场景下是否可靠”。这一多层次设计确保实验评估不仅关注最终准确率，更关注模型作为临床决策支持工具时的结构可靠性与安全边界。

6.1.4 实验模型

本实验选取 5 个开源大语言模型，覆盖不同参数规模、架构设计和训练策略，以系统分析因果增强效果的模型依赖性。模型选择如表6-4所示。

模型选择遵循以下原则：（1）规模对照：Qwen3-8B 与 Qwen3-14B 构成同架构不同规模的对照组；（2）架构对照：四个 8B 模型横向对比不同架构对因果增强效果的影响；（3）训练策略对照：DeepSeek-R1 经过推理增强训练，用于验证推理优化能

表 6-4 实验模型选择及特点

模型	参数量	架构系列	语言优势	选择理由
Qwen3-8B	80 亿	Qwen3	中英文均衡	中文理解能力强,便于处理中文检索证据
Qwen3-14B	140 亿	Qwen3	中英文均衡	与 8B 同架构,用于分析规模效应
LLaMA 3-8B	80 亿	LLaMA 3	英语为主	国际主流开源基线
LLaMA 3.1-8B	80 亿	LLaMA 3.1	英语为主	同系列迭代版本,用于分析版本提升
DeepSeek-R1-8B	80 亿	DeepSeek-R1	中英文均衡	推理增强训练,验证推理优化与因果增强的协同

否与因果约束形成协同。所有模型均通过 Ollama 本地部署，温度统一设为 0 以确保输出确定性与实验可复现性。

6.2 整体性能分析

6.2.1 不同方法的总体表现

表6-5展示了三类方案在五个模型上的整体准确率。

表 6-5 三类方案在五个模型上的整体准确率对比

模型	Pure LLM	RAG	CausalSCM
Qwen3-8B	79.03%	79.44%	91.39%
Qwen3-14B	82.78%	84.17%	92.64%
LLaMA 3-8B	79.72%	70.14%	83.19%
LLaMA 3.1-8B	80.56%	74.31%	84.44%
DeepSeek-R1-8B	77.36%	77.92%	90.83%
平均（8B 模型）	79.17%	75.45%	87.96%
平均（全部）	79.89%	77.20%	88.50%

如图6-1所示，从整体结果看，CausalSCM 在全部模型上均取得最优表现，平均准确率达到 88.50%，显著高于 Pure LLM 的 79.89% 和 RAG 的 77.20%。这一差异首先表明，在医学决策任务中，影响模型输出质量的关键因素并不只是知识是否充足，更在于知识能否以适合决策的方式被组织和调用。相较于仅依赖参数化记忆的 Pure




图 6-1 三类方案整体准确率柱状图

LLM，以及以外部文本扩展信息空间的 RAG，CausalSCM 通过显式因果关系对变量依赖、约束条件与安全边界进行预组织，因此更容易将推理过程收束到与临床判断直接相关的路径上。

进一步比较不同模型可见，因果增强的收益并非均匀分布。Qwen 系列和 DeepSeek-R1 的提升幅度均超过 9 个百分点，其中 Qwen3-8B 和 DeepSeek-R1-8B 分别提升 12.36 和 13.47 个百分点，而 LLaMA 系列仅提升约 3—4 个百分点。这意味着因果结构本身并不能自动转化为同等收益，其效果仍取决于模型是否具备吸收结构化信息并据此调整推理路径的能力。这表明因果增强并非与模型本体无关的外接模块，而是一种需要与模型内部表征能力相耦合的推理支持机制。

RAG 的表现则提供了一个有益参照。RAG 整体平均准确率为 77.20%，略低于 Pure LLM 的 79.89%，但呈现出显著的模型分化效应：对中文优化的 Qwen 系列和具有推理增强特性的 DeepSeek-R1 获得了正向增益（Qwen3-14B 提升 1.39 个百分点至 84.17%，Qwen3-8B 提升 0.41 个百分点至 79.44%，DeepSeek-R1-8B 提升 0.56 个百分点至 77.92%），而英语主导的 LLaMA 系列则出现显著退化（LLaMA 3-8B 下降 9.58 个百分点，LLaMA 3.1-8B 下降 6.25 个百分点）。这一分化表明，RAG 的有效性高度依赖于模型对中文检索证据的理解与整合能力——当模型具备良好的中文理解和批判性判断能力时，外部指南知识能提供有限但正向的辅助；反之，非结构化文本的

引入反而加剧了判断偏移^[48]。然而即便在 RAG 获益最大的模型上，其增幅也远不及 CausalSCM，进一步验证了推理约束比知识扩充更为关键这一判断。

6.2.2 因果一致性与安全鲁棒性指标

仅以整体准确率评价医学决策模型，容易掩盖“答案偶然正确但推理过程并不稳定”的问题。为与第三章提出的因果一致性评测体系形成闭环，本文进一步从因果一致性（Causal Consistency, CC）、一致性崩溃率（Consistency Collapse Rate, CCR）、安全性得分（Safety Score, SS）与鲁棒性得分（Robustness Score, RS）四个维度考察不同方案的决策可靠性。相较于准确率主要回答“是否答对”，上述指标更关注模型在事实、反事实与干扰场景之间能否保持逻辑自洽，以及其在高风险临床场景中的安全边界是否稳定。

表6-6给出了三类方案在全部五个模型上的多维指标结果。其中， $\overline{CC}$ 依据 240 组 fact-cf-adv 三联问题严格计算（三题全对记为 1，否则为 0，取平均）；CCR 统计在事实题回答正确的前提下反事实题发生崩溃的比例；SS 与 RS 则分别基于数据集中“contraindication attack”（169 条）和“confounder noise”（117 条）子集的真实预测结果得到。

如表6-6所示，从 $\overline{CC}$ 看，CausalSCM 在五个模型上的平均值达到 0.70，显著高于 Pure LLM 的 0.52 和 RAG 的 0.46。其中，Qwen3-8B 与 Qwen3-14B 在因果增强后分别从 0.47 和 0.55 提升至 0.79 和 0.80，DeepSeek-R1-8B 则从 0.47 跃升至 0.75。这说明因果增强的优势不仅体现在单题正确率上，更体现在同一问题组内部的稳定一致：模型不仅能够回答事实性问题，还能在反事实干预和对抗干扰出现时维持相对完整的因果链条。

相比之下，Pure LLM 虽然在不少单题上可以给出正确答案，但当变量条件被改写或加入干扰信息后，更容易暴露出结构理解不足的问题；RAG 的平均 CC 值为 0.46，低于 Pure LLM 的 0.52，说明外部文本的引入不仅未显著改善三联问题之间的逻辑一致性，在部分模型上甚至产生了负向干扰（如 LLaMA 3-8B 从 0.47 降至 0.35，LLaMA 3.1-8B 从 0.61 降至 0.42）。

CCR 的结果进一步揭示了上述差异的内在机制。Pure LLM 的平均一致性崩溃率为 0.17，说明约 17% 的“事实题已答对”的样本在反事实条件切换后发生了推理断裂；RAG 的平均 CCR 为 0.18，表明外部检索并未如预期那样缓解推理断裂。CausalSCM

表 6-6 因果一致性与安全鲁棒性评估结果

模型	方法	$\overline{CC}$	CCR↓	SS	RS
Qwen3-8B	Pure LLM	0.47	0.13	0.75	0.82
	RAG	0.47	0.16	0.80	0.77
	CausalSCM	0.79	0.06	0.94	0.86
Qwen3-14B	Pure LLM	0.55	0.15	0.83	0.81
	RAG	0.57	0.12	0.82	0.85
	CausalSCM	0.80	0.05	0.90	0.91
LLaMA 3-8B	Pure LLM	0.47	0.20	0.81	0.80
	RAG	0.35	0.24	0.76	0.74
	CausalSCM	0.57	0.22	0.89	0.85
LLaMA 3.1-8B	Pure LLM	0.61	0.18	0.82	0.86
	RAG	0.42	0.20	0.79	0.73
	CausalSCM	0.61	0.18	0.82	0.86
DeepSeek-R1-8B	Pure LLM	0.47	0.17	0.79	0.79
	RAG	0.47	0.18	0.77	0.75
	CausalSCM	0.75	0.09	0.91	0.88
平均（全部）	Pure LLM	0.52	0.17	0.80	0.82
	RAG	0.46	0.18	0.79	0.77
	CausalSCM	0.70	0.12	0.89	0.87

将平均 CCR 压缩至 0.12，其中 Qwen3-8B 仅为 0.06、Qwen3-14B 为 0.05、DeepSeek-R1-8B 为 0.09，说明显式因果结构确实在反事实场景中发挥了“限制错误迁移”的作用，使模型不再轻易沿用原有结论处理已经发生干预的场景。

值得注意的是，LLaMA 系列模型的 CCR 改善相对有限（LLaMA 3-8B 从 0.20 降至 0.22 反而略有上升），这与其在整体准确率上的有限提升趋势一致，进一步印证了因果增强效果具有模型依赖性。尤其值得关注的是，LLaMA 3.1-8B 在 CausalSCM 下的全部四项指标（CC=0.61、CCR=0.18、SS=0.82、RS=0.86）均与 Pure LLM 完全持平，表明因果约束对该模型未产生实质性影响。这一现象可能源于 LLaMA 3.1-8B 对中文结构化 Prompt 的解析能力不足，导致注入的因果关系未能被有效编码为推理约束。

SS 与 RS 则分别对应临床安全性与抗干扰能力。CausalSCM 的平均 SS 为 0.89，明显高于 Pure LLM 的 0.80 和 RAG 的 0.79。其中 Qwen3-8B 的 SS 从 0.75 提升至 0.94，DeepSeek-R1-8B 从 0.79 提升至 0.91，说明在涉及禁忌证与高风险方案的样本上，显式因果约束更能帮助模型优先识别否决性条件，避免因局部疗效信息而给出不安全建议。RS 方面，CausalSCM 的平均值达到 0.87，高于 Pure LLM 的 0.82 和 RAG 的 0.77，其中 Qwen3-14B 达到 0.91 的最高水平。这表明模型在面对混杂因素或表面捷径等干扰信息时，因果约束能够帮助其更稳定地聚焦真正具有决策意义的变量。更确切地说，因果增强不仅提升了“会不会做”的准确性，也提升了“在什么情况下不应做”的安全判断能力。

综合来看，准确率、 $\overline{CC}$ 、CCR、SS 与 RS 共同构成了对医学决策模型更完整的评价框架。若只考察准确率，CausalSCM 的优势可以被理解为一般性的性能改进；而在纳入因果一致性、安全性与鲁棒性后，其方法价值才得到更充分揭示：该方案真正改善的并非单点知识回忆，而是模型在条件变化、风险约束与干扰输入下维持稳定决策逻辑的能力。这也正是第三章所提出评测体系在实验层面的核心验证。

6.2.3 与已有评测结果的横向参照

为避免本文实验结论停留于“自建体系、自行验证”的封闭循环，本节将核心实验发现与已有文献报告的结果进行对照，以说明本文结论与国际前沿研究的一致性。

发现一：模型在反事实层次表现显著弱于事实层次。本文实验显示，Pure LLM 在条件型问题上的准确率（75.56%）明显低于基础型（83.33%），降幅达 7.77 个百分

点。这一递减趋势与 Jin 等^[10]在 CLadder 基准中的核心发现高度一致——该研究表明，大语言模型在因果阶梯的反事实层次上表现显著弱于关联和干预层次，且推理结构越复杂、失稳越严重。

发现二：模型推理高度依赖统计模式，分布外任务性能下降。Dziri 等^[20]发现大语言模型的推理能力严重依赖训练数据中的统计模式，在结构变化任务中性能显著退化。本文中 RAG 在 LLaMA 系列上的退化现象（LLaMA 3-8B 下降 9.58 个百分点）与之呼应：当检索到的中文指南文本超出 LLaMA 英语主导的训练分布时，非结构化知识注入不仅未能补偿，反而加剧了模型的判断偏移。

发现三：因果条件切换导致推理失稳。Kıcıman 等^[17]系统论证了大语言模型在干预和反事实任务中更易失稳的现象。本文通过 CCR 指标量化验证了这一判断：Pure LLM 的平均一致性崩溃率为 0.17，说明约 17% 的“事实题正确”样本在反事实条件切换后发生推理断裂。Chen 等^[25]在 CounterBench 中进一步证实，结构化反事实设定下模型表现会额外下降。本文嵌套型和条件型任务中 Pure LLM 的低准确率（76.67% 和 75.56%）为上述规律提供了医学领域的经验支持。

上述对照表明，本文的实验发现并非孤立结论，而是与多项独立研究的核心判断相互印证。本文的增量贡献在于：（1）在医学临床决策这一高风险场景中验证了上述规律的适用性；（2）通过 CCR、SS 等指标提供了比单一准确率更精细的量化刻画；（3）进一步证明显式因果约束能够有效缓解上述失稳现象（CausalSCM 将平均 CCR 从 0.17 压缩至 0.12，其中 Qwen3-8B 从 0.13 降至 0.06、DeepSeek-R1-8B 从 0.17 降至 0.09）。

6.3 多维度细粒度分析

6.3.1 不同类型问题的表现差异

表6-7展示了三类方案在不同问题类型上的准确率（以 Qwen3-8B 为代表）。

从问题类型看，因果增强并不是对所有任务施加均质影响，而是呈现出明显的任务选择性。Fact 类问题提升最大，达到 19.17 个百分点。这一结果表明，在事实性临床判断中，模型的主要瓶颈往往不是多步复杂推理，而是能否稳定调用正确规则并避免知识遗漏。因果图谱在此发挥的作用，更接近于将隐含于参数记忆中的规则关系显式化，使模型可以围绕“变量—条件—结论”的结构完成判断，从而降低对模糊联想和不稳定记忆召回的依赖。

表 6-7 按问题类型的准确率对比（Qwen3-8B）

问题类型	Pure LLM	RAG	CausalSCM
Fact（事实性）	72.08%	67.92%	91.25%
Counterfactual（反事实）	85.83%	85.83%	92.08%
Adversarial（对抗性）	79.17%	84.58%	90.83%
平均	79.03%	79.44%	91.39%

Counterfactual 任务的基线本身较高，而因果增强仅带来 6.25 个百分点的提升。该结果并不意味着反事实推理已经被现有模型充分解决，而恰恰揭示出其能力边界所在：模型能够进行一定程度的条件替换，但当任务要求切断原有因果来源、在新的干预条件下重组多变量关系时，仍然容易出现局部正确而整体失真的情况。从另一角度看，反事实问题要求的不只是“知道新条件是什么”，还要求模型真正理解在干预发生后，哪些原有推理路径应当被舍弃，哪些关系需要重新计算。

Adversarial 任务的改善幅度居中，说明显式因果结构对抗干扰信息具有现实作用。此类问题的难点不在于事实本身是否存在，而在于模型能否抵抗由时间压力、行政要求或表面捷径引发的错误决策倾向。CausalSCM 通过显式标记偏置变量，使模型更容易区分真正的医学依据与非医学性干扰，从而在一定程度上提升抗噪能力。但其提升幅度仍低于 Fact 类问题，说明对于对抗性推理，结构化约束虽然能够抑制部分错误路径，却尚不能完全替代更高阶的认知控制能力。

值得注意的是，RAG 在不同问题类型上的表现呈现出不对称特征。在 Counterfactual 和 Adversarial 任务上，RAG 分别达到 85.83% 和 84.58%，与 Pure LLM 基线持平或接近，说明外部指南知识在这两类任务中至少未造成负面干扰；但在 Fact 类任务上，RAG 仅为 67.92%，低于 Pure LLM 的 72.08%，下降了 4.16 个百分点。这一不对称反映了 RAG 系统的核心矛盾：当检索到的证据覆盖了一般治疗推荐时，模型在反事实和对抗性问题上能够据此正确判断；然而对于 Fact 类问题（正确答案多为 No，需识别禁忌条件），检索结果中的“推荐性”证据反而诱导模型过度肯定，从而导致假阳性增加。这进一步表明，在涉及否决性判断的任务中，结构化因果约束比非结构化文本补充更具针对性。

6.3.2 不同疾病类别的影响

图6-2展示了三类方案在六种疾病上的准确率（以 Qwen3-8B 为代表）。




图 6-2 按疾病类别的准确率柱状图（Qwen3-8B）

如图6-2所示，不同疾病类别上的结果说明，因果增强的收益不仅取决于模型能力，也与具体领域中知识的组织方式密切相关。以前列腺癌（PS）为例，CausalSCM准确率达到 97.50%，接近任务上限。该领域决策常围绕 PSA 水平、Gleason 评分及风险分层等结构清晰的规则展开，变量关系相对稳定，因而更容易被转写为明确的因果依赖网络。在此类规则边界清晰、条件层级明确的任务中，因果图谱能够有效承担决策骨架的角色。

急性髓细胞白血病（AML）的表现则揭示了另一种机制。其 Pure LLM 基线最低，但因果增强的改善幅度最大，达到 18.33 个百分点。这说明 AML 任务的困难并不主要来自孤立知识点缺失，而更多来自分子分型、风险分层与治疗策略之间高度耦合的关系结构。因果增强在此并不是简单补充“更多事实”，而是帮助模型把复杂但彼此相关的信息重新编排为可执行的判断路径，从而减少碎片化知识调用所导致的推理混乱。

中枢神经系统肿瘤（CNS）的提升幅度最小，仅为 6.67 个百分点。该结果提示了因果增强的重要边界：当临床判断较大程度依赖影像学特征、手术可行性或其他

难以在纯文本中充分离散化表达的信息时，文本化因果图谱能够提供的帮助将受到限制。也就是说，因果增强在高度规则化、变量关系明确的任务中最具优势，而在弱结构、强多模态依赖的场景中，其效力自然趋于减弱。

RAG 在疾病维度上的表现呈现出与整体趋势一致的分化特征。前列腺癌（PS）领域 RAG 表现最优（88.33%），高于 Pure LLM 的 82.50%，得益于该领域指南的高度结构化与治疗路径的标准化程度；小细胞肺癌（SCLC）的 RAG 表现（83.33%）同样高于 Pure LLM（77.50%），说明在分期清晰、方案规范的领域，RAG 检索能够有效补充决策支持。然而，对于亚型复杂的 AML（RAG 80.00% vs Pure LLM 74.17% 虽有提升，但提升有限）和 CNS（RAG 76.67% vs Pure LLM 80.83% 反而下降），以及 WM/LPL（RAG 71.67% vs Pure LLM 75.83% 下降），RAG 的增益受到限制甚至转为负面。这进一步表明，在疾病亚型复杂、治疗决策涉及多层次条件交互的领域，非结构化文本检索难以精确匹配具体临床情境，而通用性检索结果可能引入噪声或误导性证据。

6.3.3 模型规模与架构的作用

为探究模型规模和架构对因果增强效果的影响，本文进一步比较了不同模型的表现。

6.3.3.1 参数规模的影响

对比 Qwen3-8B 与 Qwen3-14B（相同架构、不同规模）的结果如表6-8所示。

表 6-8 模型规模对因果增强效果的影响			
模型	Pure LLM	CausalSCM	改进幅度
Qwen3-8B (80 亿参数)	79.03%	91.39%	+12.36pp
Qwen3-14B (140 亿参数)	82.78%	92.64%	+9.86pp
规模提升效果	+3.75pp	+1.25pp	-2.50pp

结果显示，更大参数规模确实带来了更高的基线性能：Qwen3-14B 在 Pure LLM 条件下比 Qwen3-8B 高出 3.75 个百分点，表明参数增长有助于提升模型对医学知识的覆盖能力与记忆稳定性。然而，在引入因果增强后，14B 模型相对 8B 模型的额外

收益仅为 1.25 个百分点，其绝对改进幅度反而由 12.36 个百分点下降至 9.86 个百分点。该现象体现出明显的边际收益递减：当模型自身的知识表征已较充分时，外部结构约束更多承担校准功能，而不再像中等规模模型那样产生显著的补偿作用。

这一结果说明，参数规模与因果增强并不是替代关系，而是作用于不同层面的两种能力来源。前者主要提高模型在无显式约束条件下的默认判断水平，后者则改善模型在面对复杂条件依赖时的决策一致性。也就是说，大模型并不会自然消解结构化约束的价值；相反，当任务具有明确的安全规则和变量层级时，因果增强仍能提供超出规模扩张本身的稳定收益。

6.3.3.2 模型架构的影响

对比相同规模（8B）的不同架构模型，结果如表6-9所示。

表 6-9 模型架构对因果增强效果的影响

模型（8B 参数）	Pure LLM	CausalSCM
Qwen3-8B	79.03%	91.39%
LLaMA 3-8B	79.72%	83.19%
LLaMA 3.1-8B	80.56%	84.44%
DeepSeek-R1-8B	77.36%	90.83%

相较于参数规模，模型架构带来的差异更加显著。Qwen3-8B 与 DeepSeek-R1-8B 在引入因果增强后均实现了接近 60% 的错误率下降，而 LLaMA 系列仅维持在 20% 以下。这表明，决定因果增强效果的关键因素并不仅是模型容量，更在于模型是否擅长将外部结构化信息吸收为实际推理步骤。尤其是 DeepSeek-R1 虽然在 Pure LLM 条件下基线最低，但在因果增强后迅速提升至 90.83%，说明推理优化导向的模型更容易与显式因果结构形成协同。

LLaMA 3.1 相较 LLaMA 3 虽有小幅改善，但整体收益仍然有限。这提示我们，因果推理能力并不会仅由参数扩张或一般指令遵循能力自然产生，它更可能依赖于预训练分布、后续推理训练目标以及模型内部对结构化关系的编码偏好。由此可见，在医学决策场景中，”记住医学知识”与”理解因果结构”是两个相关但不可等同的能力维度，而本文方法的有效性正建立在后者可被外部约束显式激活这一事实上。

6.3.4 逻辑维度的分层表现

为检验第三章提出的双维度分类体系在实验中的区分效力，本文进一步按逻辑维度（基础型、联合型、嵌套型、条件型）分析三类方案的表现差异。表6-10展示了 Qwen3-8B 在不同逻辑维度上的准确率。

表 6-10 按逻辑维度的准确率对比（Qwen3-8B）

逻辑维度	Pure LLM	RAG	CausalSCM	CausalSCM 提升
基础型（Basic）	83.33%	82.78%	95.00%	+11.67pp
联合型（Joint）	80.56%	80.00%	91.67%	+11.11pp
嵌套型（Nested）	76.67%	77.22%	89.44%	+12.77pp
条件型（Conditional）	75.56%	77.78%	89.44%	+13.88pp
平均	79.03%	79.44%	91.39%	+12.36pp

从表6-10可以观察到两个值得关注的趋势。

第一，Pure LLM 的表现随逻辑复杂度递增而递减。基础型准确率为 83.33%，条件型降至 75.56%，降幅达 7.77 个百分点。这一递减趋势符合因果阶梯理论的预期：模型在处理局部单变量干预时表现较好，但在面对多变量联合干预（联合型）、链式传播推理（嵌套型）以及反事实回溯（条件型）时，推理负担逐步增加，错误率随之上升。RAG 的表现同样呈现类似的递减趋势，说明非结构化知识补充无法有效缓解推理结构复杂度带来的挑战。

第二，CausalSCM 在高复杂度任务上的提升幅度反而更大。条件型提升 13.88 个百分点，嵌套型提升 12.77 个百分点，均高于基础型的 11.67 个百分点。这说明因果约束对推理结构越复杂的任务越具有不可替代性。在基础型任务中，模型依靠参数化知识已完成大部分判断，因果约束主要起到校准作用；而在嵌套型和条件型任务中，模型面临的是多步推理链维护和反事实回溯等结构性困难，此时显式因果路径能够直接为模型提供推理骨架，显著减少中间步骤的错误传播。

为进一步将逻辑维度分析从准确率层面延伸至第三章所定义的因果一致性层面，表6-11给出了三类方案在不同逻辑维度上的分层因果一致性 $\overline{CC}_l$ （以 Qwen3-8B 为代表）。

表 6-11 按逻辑维度的因果一致性 $\overline{CC}_l$ 对比（Qwen3-8B）

逻辑维度	Pure LLM	RAG	CausalSCM
基础型（Basic）	0.46	0.48	0.80
联合型（Joint）	0.42	0.47	0.80
嵌套型（Nested）	0.44	0.46	0.77
条件型（Conditional）	0.61	0.45	0.78
整体 $\overline{CC}$	0.47	0.47	0.79

如表6-11所示， $\overline{CC}_l$ 的分析揭示了与单题准确率不同的模式。Pure LLM 在各逻辑维度上的因果一致性均低于 0.50（条件型略高为 0.61），表明即使准确率尚可，模型在同一问题组内部的三联一致性仍较差。CausalSCM 则在四个逻辑维度上均将 $\overline{CC}_l$ 提升至 0.77 以上，尤其在基础型和联合型任务中实现了从 0.42–0.46 到 0.80 的大幅跃升。值得注意的是，嵌套型和条件型的 $\overline{CC}_l$ 虽然也显著提升，但仍略低于基础型，说明多步推理链的维护即便在因果约束辅助下仍具有一定挑战性。这一结果与第三章所预期的“ $\overline{CC}_l$ 随逻辑复杂度递增而递减”的理论假设基本一致，验证了分层因果一致性指标的区分效力。

6.3.5 跨模型综合对比

为提供更全局的实验视角，表6-12汇总了全部五个模型在三类方案下的核心指标对比。

表 6-12 五个模型在三类方案下的核心指标综合对比

模型	准确率 (%)			CausalSCM vs Pure LLM	
	Pure	RAG	Causal	ΔAcc	$\text{RAG}\Delta$
Qwen3-8B	79.03	79.44	91.39	+12.36	+0.41
Qwen3-14B	82.78	84.17	92.64	+9.86	+1.39
LLaMA3-8B	79.72	70.14	83.19	+3.47	-9.58
LLaMA3.1-8B	80.56	74.31	84.44	+3.88	-6.25
DeepSeek-R1	77.36	77.92	90.83	+13.47	+0.56
平均	79.89	77.20	88.50	+8.61	-2.69

注： ΔAcc 为 CausalSCM 相对 Pure LLM 的准确率提升（百分点）， $\text{RAG}\Delta$ 为 RAG 相对 Pure LLM 的准确率变化（百分点）。

表6-12清晰呈现了三个核心发现：**（1）因果增强的普适性：**CausalSCM 在全部五个模型上均实现正向提升，平均准确率提升 8.61 个百分点，证明该方法并非针对特定模型的局部优化，而是一种具有跨架构适用性的推理增强范式。**（2）因果增强的模型依赖性：**提升幅度在不同架构间存在显著差异，Qwen 系列和 DeepSeek-R1 的提升均超过 12 个百分点，而 LLaMA 系列不足 4 个百分点，表明因果约束效果与模型对结构化信息的吸收能力高度相关。**（3）RAG 的不稳定性：**RAG 在两个模型上产生负面效果（LLaMA 3-8B 下降 9.58 个百分点），平均准确率甚至低于 Pure LLM 基线，说明在当前任务条件下非结构化知识补充并不是可靠的改进路线。

综合上述多维度分析，可以更为明确地界定三类方法的能力边界：Pure LLM 受限于参数化知识的不稳定调用，在结构复杂度较高的任务上表现明显下降；RAG 虽试图通过外部知识弥补这一不足，但受限于检索噪声和表示形式不匹配，其收益高度依赖模型的语言适配能力，且即便在最优条件下增幅也极为有限；CausalSCM 则通过显式因果约束直接干预推理结构，在不同复杂度层次、不同疾病领域和不同模型架构上均展现出最为稳定和显著的改进效果。

6.4 错误分析与能力边界

为进一步理解因果增强为何有效、又为何仍然存在残余错误，本文对 Qwen3-8B 模型的错误案例进行了系统分析。

6.4.1 错误类型转移

基于对模型输出的归因，本文将错误划分为推理能力错误、医学知识错误和理解能力错误三类，统计结果如表6-13所示。

表 6-13 Qwen3-8B 错误能力归因分析

错误类型	Pure LLM	CausalSCM	变化趋势
推理能力错误	低占比	39 例 (62.9%)	↑ 显著增加
医学知识错误	隐性主导	8 例 (12.9%)	↓ 大幅减少
理解能力错误	1 例 (0.7%)	1 例 (1.6%)	→ 基本持平
总错误数	151 例	62 例	-89 例 (-58.9%)

最值得关注的并不仅是总错误数由 151 例下降至 62 例，而是错误结构本身发生

了变化。在 Pure LLM 条件下，模型更常见的问题是无法稳定调用关键医学规则，即便能够理解题面，也容易因为知识检索不足或规则激活失败而做出错误判断；而在 CausalSCM 条件下，知识性错误大幅减少，剩余错误则主要集中在多条件推理、优先级协调和全局权衡等更高阶的环节。因果增强首先压缩的是“知道什么”层面的失误，随后暴露出的才是“如何推理”层面的真实短板。

这种错误类型转移具有清晰的方法论含义。它表明 CausalSCM 并非在所有能力维度上平均增益，而是优先消除了最容易通过显式结构纠正的那部分错误。随着知识性失误被剔除，模型剩余问题自然更多表现为真正的推理困难。因此，因果增强不仅是一种性能提升手段，也是一种能力边界显化机制：它使模型的弱点从“知识调取不稳定”转移到“复杂推理仍然不足”，从而让后续改进方向更加明确。

6.4.2 成功案例：知识补偿

在药物禁忌症识别任务中，因果增强表现出典型的知识补偿作用。以题目 ALL_002_fact 为例，患者在接受培门冬酶治疗期间发生 4 级急性坏死性胰腺炎，临床问题是能否改换另一种门冬酰胺酶制剂继续治疗。Pure LLM 给出了错误的“**Yes**”判断，说明模型虽然抓住了“换药后继续治疗”这一表面操作，却未能稳定调用“4 级严重毒性构成绝对禁忌症”这一关键规则。CausalSCM 则沿着“4 级毒性 → 绝对禁忌 → 不可换用同类药物”的显式关系得出正确结论。

这一案例说明，因果结构在部分任务中承担的并不仅是推理支架，更是一种结构化知识外显机制。原本分散、隐含于参数中的临床规则，被重写为明确的变量关系和判断路径，模型不再完全依赖模糊的相似性联想完成选择。这也是 Fact 类问题改进最为明显的原因之一：在这类任务中，因果增强首先提升的不是推理深度，而是知识调用的确定性与规则执行的一致性。

6.4.3 失败案例：多因素权衡

然而，因果增强并不能自动解决复杂临床决策中的多因素优化问题。以题目 ALL_004_cf 为例，患者 72 岁、确诊 Ph+ ALL 且身体虚弱，问题是是否仍应首选 TKI 联合高强度化疗。正确答案应为 No，因为老年且虚弱的患者更适合低强度方案。CausalSCM 虽然已正确识别年龄、疾病亚型和虚弱状态等关键信息，但仍错误输出“**Yes**”，说明模型即便获得了正确变量，也未必能够稳定完成多条因果路径之间的全局协调。

这类错误的症结并不在于模型未看到关键条件，而在于无法赋予不同条件以恰当的决策优先级。例如，Ph+ ALL 提示 TKI 具有适应症意义，但“老年 + 虚弱”又对高强度化疗形成强约束。若模型不能正确处理疗效收益与安全边界之间的层级关系，就容易出现局部规则都被识别、最终结论却仍错误的现象。因此，因果关系在复杂任务中往往只是必要条件，而非直接推出最优方案的充分条件；真正的瓶颈转移到了多因素联合推理与策略权衡能力。

6.4.4 持续错误分布

在采用 CausalSCM 时，剩余 62 道错题按临床模块分布如图6-3所示。




图 6-3 CausalSCM 持续错误的临床模块分布饼图（Qwen3-8B，共 62 例）

如图6-3所示，持续错误的分布进一步印证了上述判断。适应症检查、混杂因素干扰与共病交互三类问题合计占比超过 80%，其共同特征在于需要模型在多个变量之间动态分配权重，而非仅沿单一因果链完成顺序推理。相比之下，禁忌症攻击模块错误最少，仅占 16.1%，说明当任务可被压缩为较为清晰的否决性规则时，因果增强最能稳定发挥作用。

由此可以更清楚地界定 CausalSCM 当前的能力轮廓：其优势主要体现在规则一致性判断，即帮助模型更稳地识别“能否做”“是否禁止”“是否违反安全边界”；而其薄弱环节则集中在复杂条件下的综合优化，即面对多个同时成立且彼此牵制的条

件时，模型仍缺乏足够稳定的全局决策能力。

6.5 RAG 方法效果分析

前文已指出 RAG 呈现显著的模型分化效应。本节进一步分析其效果受限的深层原因及其与因果增强的机制差异。

6.5.1 RAG 效果受限的原因分析

RAG 效果受限的原因可归结为两个层面。**第一，检索噪声与表示形式不匹配。**尽管系统已通过疾病感知路由和多查询变体扩展提高召回针对性，但非结构化文本仍难以精确对应医学决策所需的条件-结论结构。RAG 提供的是自然语言片段，而医学决策要求明确区分适应症、禁忌症及其优先级关系，模型需承担额外的结构恢复成本。**第二，认知负担增加。**检索引入的多条证据片段显著增加了输入上下文的长度与信息密度，对 8B 级模型而言，在较长上下文中同时完成证据筛选、关系判断与结论生成的认知负担可能超过知识补充带来的收益^[48]。

6.5.2 与因果增强的机制差异

表6-14给出了 RAG 与 CausalSCM 的核心差异对比。

表 6-14 RAG 与 CausalSCM 的对比

维度	RAG	CausalSCM
知识来源	外部检索（NCCN 指南）	数据集自带因果图谱
知识形式	自然语言文本片段	结构化因果关系
推理引导	隐式（依赖模型自主整合）	显式（通过因果约束）
核心假设	知识不足导致决策失误	错误推理路径导致决策失误
平均准确率	77.20%	88.50%

二者最根本的差异在于对模型推理空间的处理方式：**RAG** 通过引入更多候选信息扩展搜索范围，**CausalSCM** 则通过显式因果关系压缩搜索空间。实验结果表明，在高风险医学决策任务中，后者更符合任务需求，因为核心困难往往不是”事实不足”，而是”如何避免沿错误路径得出看似合理的结论”。

6.6 因果增强机制分析与理论解释

6.6.1 问题重述：因果增强改变了什么

前文实验已表明 CausalSCM 在多项指标上取得显著提升，但仅将其归因于“加入了更多知识”不足以解释其差异化收益。结合各维度的实验结果可以看到，因果增强真正改变的并非信息量本身，而是信息在推理链中的组织方式——它通过重新界定变量优先级与约束边界，对模型的决策路径施加了结构性干预。

6.6.2 因果增强有效性的理论依据

本文 CausalSCM 的实验收益（平均准确率提升 8.61 个百分点）并非偶然发现，而是可以从因果推理理论与神经符号 AI 研究中获得解释。Pearl^[2]的因果阶梯理论明确指出，仅靠关联层数据（即统计模式）无法稳定获得干预层和反事实层的推理能力，因为后两者要求对变量间的因果方向和干预效应进行显式建模。本文实验中 Pure LLM 在条件型问题上的性能下降（相对基础型降低 7.77 个百分点）正是这一理论预测的经验体现。

Garcez 和 Lamb^[51]在神经符号 AI 框架中进一步论证，将显式逻辑约束与神经网络推理相结合，能够显著提升系统在结构化推理任务中的可靠性与可解释性。本文 CausalSCM 将因果图谱以结构化规则形式注入 Prompt，本质上实现了一种轻量级的神经符号融合——模型作为神经推理引擎，因果图谱作为符号约束层，二者协同完成临床决策。实验结果（平均 CC 从 0.52 提升至 0.70，Qwen3-8B 的 CC 从 0.47 提升至 0.79，平均 CCR 从 0.17 压缩至 0.12）为上述理论框架在医学领域提供了具体经验验证。

6.6.3 因果增强的三层作用机制

从实验现象出发，因果增强至少在知识层、推理层和决策层三个层面发挥作用。首先在知识层面，它将原本隐含于参数中的临床规则外显化为变量与关系。Fact 类任务提升最大，正说明当模型不必再依赖不稳定的记忆召回，而能够直接围绕“毒性等级、适应症、禁忌症”等显式变量进行判断时，知识调用的确定性会显著提高。这一过程本质上实现了从隐式统计相关到显式规则结构的转化。

其次在推理层面，因果图谱能够对模型的搜索空间进行裁剪。Pure LLM 在面对复杂问题时，往往容易沿若干高表面相关却非真正关键的路径进行联想式推理；而

CausalSCM 通过提供变量依赖关系，缩小了模型可能采纳的路径集合，使其更容易围绕与临床决策直接相关的条件组织分析。Adversarial 任务中的性能改善正可由此解释：模型并不是“知道得更多”，而是在更受约束的空间中完成了更稳健的判断。

最后在决策层面，因果结构还承担了变量优先级重排序的作用。医学判断中的不同因素并非平行并列，例如禁忌症通常高于一般适应症，安全边界在特定条件下也可能压倒疗效收益。Pure LLM 未必能够稳定学习这种层级秩序，而因果图谱通过显式依赖关系将这种优先级部分外部化，因此在禁忌症识别和规则排除类任务中表现尤为突出。不过，失败案例表明，多因素联合优化仍是当前短板，这说明现有结构表达虽能提供优先级线索，但尚不足以完全支持复杂临床决策中的全局最优求解。

6.6.4 因果增强的能力边界

尽管 CausalSCM 取得了最优整体性能，但实验同样清楚地表明，其提升并非没有边界。首先，在多因素交互问题中，现有因果图谱主要提供的是局部变量关系和相对明确的条件约束，而真实医学决策常涉及非线性耦合、动态风险平衡以及隐含条件切换。对于这类问题，因果图谱可以指出“哪些因素重要”，却未必能够充分表达“这些因素如何联合优化”。

其次，因果增强更擅长回答“是否可行”，而不一定擅长回答“何者最优”。禁忌症识别、适应症排除等任务天然适合通过因果约束建模，因为它们强调规则一致性与安全底线；但当问题上升到多个可行方案之间的优选比较时，模型不仅需要因果路径，还需要更强的效用权衡与策略优化能力。本文中的持续错误正主要集中在这一层面。

最后，纯文本因果建模对多模态信息的承载能力有限。影像学特征、病理细节、手术可行性乃至经验性临床判断等因素，在现实医疗场景中都可能决定最终结论，但这些信息并不能被当前的数据表示方式完整吸收。因此，本文认为因果增强当前主要解决的是“规则一致性问题”，而不是“全局最优临床决策问题”。这一判断既解释了其显著有效性，也为后续研究指出了继续融合更复杂结构与多模态信息的方向。

6.7 小结

本章围绕 MedCausalBenchmark 数据集，对 Pure LLM、RAG 与 CausalSCM 三类方案进行了系统比较与多维度分析。核心实验发现可概括为以下三点。

第一，CausalSCM 在全部模型上均取得最优表现，且其优势不仅体现在准确率层面，更体现在因果一致性、安全性与鲁棒性等结构可靠性指标上。第二，RAG 的有效性高度依赖于模型对检索证据的语言适配能力，在当前任务条件下并非稳定可靠的改进路线。第三，因果增强的核心价值不在于扩大信息总量，而在于通过显式化临床规则、约束推理路径与重排序变量优先级来压缩错误空间，使模型的错误类型从知识性失误向高阶推理困难转移，从而令能力边界更加可识别。

与此同时，实验也揭示了该方法的现实边界：当任务涉及复杂多因素权衡、最优策略选择或多模态信息整合时，现有因果结构仍难以完全覆盖真实临床决策的全部复杂性。基于上述分析，第七章将进一步总结本文的主要贡献，讨论现阶段方法的局限，并展望后续研究的可能拓展。

第7章 总结与展望

本文围绕面向医学临床决策的大语言模型因果一致性评测基准构建与分析这一研究主题展开。针对现有医学大语言模型评测偏重事实记忆、缺乏对反事实推理能力与因果一致性系统刻画的不足，本文构建了面向临床决策场景的因果一致性评测框架与基准数据集，并在统一实验系统中对多种技术路线进行了系统比较。全文从问题定义、理论建模、数据集构建、系统实现到实验验证逐步展开，形成了完整的研究链路。本章在此基础上，对主要研究内容、核心结论、创新意义、现存局限与未来研究方向进行系统总结。

7.1 主要研究工作与研究结论

7.1.1 主要研究工作

围绕大语言模型能否真正理解干预、禁忌、共病与混杂因素所引起的因果变化这一核心问题，本文完成了以下四方面工作：（1）以结构因果模型为理论基础，构建因果一致性评测体系，提出双维度分类框架与 CC、CCR、SS、RS 等量化指标^[2,56]；（2）构建 MedCausalBenchmark 数据集，覆盖 6 类疾病、720 条事实—反事实—对抗三元组样本；（3）实现统一评测系统，在相同实验条件下对 Pure LLM、RAG 与 CausalSCM 三类方案进行对比评估；（4）通过系统实验验证显式因果结构对提升医学临床推理可靠性的有效性，并深入分析各方案的失效模式与能力边界。

7.1.2 主要研究结论

基于前文的理论构建与实验分析，本文得出以下主要结论。

第一，显式因果结构能够显著提升大语言模型在医学临床决策中的因果一致性。相较于单纯依赖参数化知识记忆与表层语言模式匹配，当模型获得明确的变量关系、干预方向与决策约束时，其在适应证判断、禁忌证识别和复杂条件变化应对中能够维持更为稳定的推理逻辑。这表明，决定模型临床推理可靠性的关键不仅在于知识储备的广度，更在于能否依据正确的因果结构组织和运用知识。

第二，因果增强方法在整体性能、安全性与鲁棒性方面均展现出稳定优势。实验结果表明，CausalSCM 方法在识别错误治疗路径、抵御表层干扰以及维持条件变化后推理一致性等方面，均优于 Pure LLM 与 RAG 方案。结构化因果知识不仅提升

了回答正确率，更强化了模型在高风险场景中的安全边界与抗干扰能力。

第三，非结构化检索增强未必适合医学因果决策任务。实验发现，RAG 虽能引入额外知识，但当检索内容缺乏与因果推理过程相匹配的结构化组织时，可能引入噪声并增加推理负担。这表明，在高专业性、强约束性的医学决策任务中，知识的组织形式与供给方式的重要性不亚于知识总量——结构化、可推理的知识表示优于非结构化文本证据的简单堆叠。

第四，当前大语言模型在深层反事实推理与多因素权衡方面仍存在显著瓶颈。尽管因果增强可缓解部分推理错误，但面对多变量联动、复杂共病关系及治疗收益—风险权衡等问题时，模型仍易出现推理链断裂、错误归因或局部条件忽视等问题。这表明，显式因果结构能够显著改善一致性表现，但尚不足以完全克服复杂临床推理中的深层困难。

第五，本文构建的评测框架与基准数据集为医学 AI 可靠性研究提供了可复用的分析工具。通过将正确性与因果一致性同时纳入评价体系，本文为后续研究者在不同模型、知识增强策略与医学任务设置下的推理可靠性比较提供了统一基线，也为临床辅助决策系统的风险评估与方法迭代提供了实证支撑。

7.2 研究创新点与实际意义

7.2.1 研究创新点

本文的创新主要体现在以下四个方面。

第一，在研究视角上，本文将医学大语言模型评测的核心关注点从事实问答正确性拓展至因果一致性与反事实推理能力的系统评估，明确提出临床决策场景下模型不仅需回答正确，更需推理可靠。这一评测视角更贴近真实医疗环境对智能决策系统的核心要求。

第二，在理论框架上，本文以结构因果模型为基础，将干预、禁忌、混杂与共病等临床因果约束统一纳入评测体系，构建了逻辑维度与医学维度相结合的双维度分类框架，使医学推理任务得以在更细粒度上进行拆解与分析，增强了评测结果的可解释性与诊断价值。

第三，在数据资源上，本文构建了 MedCausalBenchmark 数据集，通过事实、反事实与对抗三类样本的结构化对应设计，将知识考察、因果干预分析与对抗鲁棒性测试融合于同一评测基准，为后续相关研究提供了可扩展的数据基础^[14-15]。

第四，在实验分析上，本文不仅对 Pure LLM、RAG 与 CausalSCM 三类方案的整体表现进行了横向比较，还从安全性、鲁棒性与错误类型等多维视角揭示了不同知识增强策略的有效边界与失效机制，为医学 AI 系统的架构选型提供了具有针对性的证据支持。

7.2.2 实际应用意义

本文的实际意义主要体现在以下四个方面。

第一，从评测标准建设角度看，本文提出的因果一致性评测框架有助于推动医学大语言模型评价体系从静态知识测试向动态决策能力评估演进。因果一致性、安全性与鲁棒性等指标较传统问答准确率能够更真实地反映模型在临床高风险场景中的应用潜力。

第二，从系统架构设计角度看，实验结果表明将结构化因果知识显式引入推理过程是提升医学决策辅助系统可靠性的有效路径。这一发现对后续面向专病诊疗、临床路径推荐、用药安全审查等应用场景的智能系统构建具有直接参考价值^[2]。

第三，从研究资源建设角度看，MedCausalBenchmark 可作为后续方法研究、模型对比与误差分析的公共测试基础，既支持不同模型间的横向比较，也支持同一模型在提示优化、知识增强与推理控制等维度上的纵向改进评估。

第四，从临床安全治理角度看，本文明确提出医学 AI 系统在部署前应接受因果一致性层面的专项评估，这对于降低模型在禁忌证识别失误、共病处理失当及反事实判断偏差等方面的潜在风险具有现实意义^[4,6]。

7.3 研究局限性

尽管本文在医学因果一致性评测方面进行了较为系统的探索，但仍存在以下局限。

第一，数据集覆盖范围有限。MedCausalBenchmark 主要基于特定疾病领域与临床指南场景构建，虽已涵盖适应证、禁忌证、共病与混杂因素等核心模块，但在疾病谱广度、病例复杂程度与临床情境多样性方面仍有不足，尚难以全面代表真实临床决策的复杂性。

第二，评测任务形式相对受控。本文采用结构化问题与标准答案对应的实验方式，虽有利于定量比较与误差归因，但对真实临床环境中开放式问答、多轮交互及

长程病史整合等复杂任务形态的覆盖尚不充分。因此，所得结论更适用于受控条件下的模型能力比较，不宜直接等同于真实临床部署表现。

第三，因果图与样本构建具有较强的专家依赖性。因果关系抽取、变量定义及干预路径设计均依赖权威指南梳理与专业知识校验，构建成本较高，制约了数据集向更大疾病范围的快速扩展。

第四，实验验证局限于文本决策场景。真实临床判断往往需综合病历文本、实验室指标、影像信息及时间序列监测数据，而本文尚未将多模态临床信息纳入评测框架，对模型综合决策能力的刻画仍不充分。

第五，因果增强的效果边界尚待进一步探索。尽管实验验证了显式因果结构的有效性，但模型在复杂反事实推理、多因素联合权衡与深层临床逻辑迁移方面仍表现出明显不足，表明因果结构更多地为模型提供了稳定的推理支架，而非从根本上突破大语言模型深层推理能力的瓶颈。

7.4 未来研究展望

基于本文的研究基础与上述局限，未来可从以下方向深入推进。

第一，深化面向复杂临床推理的因果建模。可围绕多步反事实推理、治疗收益—风险联合权衡及长期预后推断等高难度任务，设计更精细的因果推理链条与更具区分度的评测场景，以系统刻画模型在深层决策过程中的能力边界与衰减规律。

第二，探索医学因果图的自动化构建方法。可融合临床指南解析、知识图谱构建、信息抽取与因果发现等技术，提升因果关系建模效率；同时引入专家在环校验机制，在保障图谱质量的前提下增强可扩展性，降低大规模基准构建的人力成本。

第三，拓展评测基准的疾病覆盖范围与临床场景复杂度。可将本文框架推广至心血管、感染、代谢及神经系统等疾病领域，并纳入多学科协同诊疗、复杂并发症管理与个体化治疗决策等场景，以提升评测结论的普适性与临床代表性。

第四，构建多模态因果一致性评测体系。临床决策并非仅依赖文本信息，未来应将影像数据、检验指标、病理结果与时序监测数据纳入统一的因果评测框架，构建能够反映真实临床工作流的多模态医学推理基准。

第五，加强基准研究与真实临床验证的衔接。后续工作不应局限于基准性能的提升，还应关注系统在实际医疗流程中的可解释性、可审计性与风险可控性，通过临床试点验证或多中心专家评估，检验因果增强方法在真实部署环境中的有效性与

安全性。

7.5 本章小结

本章对全文研究进行了系统回顾与总结。本文围绕医学临床决策中大语言模型因果一致性评测这一核心问题，构建了评测框架、基准数据集与统一实验系统，实验结果验证了显式因果结构对提升模型一致性、安全性与鲁棒性的积极作用。同时，研究也揭示了当前模型在复杂反事实推理、多因素联合决策与多模态信息整合方面的明显不足。本文为推动医学 AI 评测从知识问答正确性评估走向临床推理可靠性评估提供了可操作的研究路径，也为后续构建高可信临床智能系统奠定了理论与实证基础。

结 论

本文面向医学临床决策场景，围绕大语言模型在反事实推理、禁忌识别和复杂条件变化下因果一致性不足的问题，系统开展了评测基准构建、评测体系设计与实验分析研究。针对现有医学大语言模型评测主要聚焦事实性知识问答、难以有效反映模型临床推理可靠性的不足，本文以结构因果模型为理论基础^[2,56]，构建了兼顾逻辑复杂度与医学决策特征的因果一致性评测框架，并提出因果一致性、因果一致性崩塌率、安全性得分和鲁棒性得分等评价指标，从而实现了“是否答对”与“是否按照正确医学因果逻辑作答”的联合评价。

在数据资源构建方面，本文基于 NCCN 等权威临床指南，设计并构建了 MedCausalBenchmark 评测数据集。该数据集采用 Fact、Counterfactual 和 Adversarial 三元组结构，覆盖 6 类疾病、720 条样本，能够系统刻画模型在原始事实判断、干预条件变化和对干扰场景下的推理表现，为医学因果一致性研究提供了可复用、可扩展的测试基础^[14-15,53-54,58]。

在实验研究方面，本文实现并比较了 Pure LLM、RAG 和 CausalSCM 方法三类方案。结果表明，相较于单纯依赖参数记忆或非结构化文本检索的方案，显式引入结构化因果知识能够更有效地提升模型在医学临床决策中的一致性、安全性与鲁棒性；同时，实验也表明当前模型在深层反事实推理、多因素联合权衡与复杂临床条件迁移方面仍存在明显不足^[2,48]。这说明医学大语言模型的可靠性提升不能仅依赖知识扩充，更需要面向临床决策机制本身构建可解释、可约束、可验证的推理框架。

总体而言，本文的主要创新在于：构建了面向医学临床决策的因果一致性评测体系，提出了 MedCausalBenchmark 评测基准，并通过系统实验揭示了显式因果结构对医学 AI 可靠性提升的积极作用及其能力边界。相关研究为后续医学大语言模型评测、知识增强和安全治理提供了新的分析视角，也为高可信临床智能辅助决策系统的构建奠定了方法基础。未来仍需围绕自动化因果图构建、跨疾病迁移、多模态信息融合及真实临床验证等方向持续深入，以进一步推动医学人工智能由“会回答”走向“能可靠决策”。

参考文献

- [1] Pearl J, Mackenzie D. The Book of Why: The New Science of Cause and Effect[M]. New York: Basic Books, 2018.
- [2] Pearl J. Causality: Models, Reasoning, and Inference[M]. 2nd. Cambridge: Cambridge University Press, 2009.
- [3] Zhou H, Liu F, Gu B, et al. A Survey of Large Language Models in Medicine: Progress, Application, and Challenge[J]. arXiv preprint arXiv:2311.05112, 2024.
- [4] Singhal K, Azizi S, Tu T, et al. Large Language Models Encode Clinical Knowledge[EB/OL]. 2022. <https://arxiv.org/abs/2212.13138>.
- [5] Singhal K, Tu T, Gottweis J, et al. Towards Expert-Level Medical Question Answering with Large Language Models[EB/OL]. 2023. <https://arxiv.org/abs/2305.09617>.
- [6] Nori H, King N, McKinney S M, et al. Capabilities of GPT-4 on Medical Challenge Problems [EB/OL]. 2023. <https://arxiv.org/abs/2303.13375>.
- [7] Tian Y, Gan R, Song Y, et al. ChiMed-GPT: A Chinese Medical Large Language Model with Full Training Regime and Better Alignment to Human Preferences[EB/OL]. 2024. <https://arxiv.org/abs/2311.06025>.
- [8] 马武仁, 弓孟春, 戴辉, 等. 以 ChatGPT 为代表的大语言模型在临床医学中的应用综述[J]. 医学信息学杂志, 2023, 44(7): 1-9.
- [9] 钟贵鑫, 李佳根, 何雄, 等. 国内外大语言模型在临床医学中的应用探讨[J]. 医学理论与实践, 2025, 38(14): 2371-2374, 2385.
- [10] Jin Z, Chen Y, Leeb F, et al. CLadder: Assessing Causal Reasoning in Language Models[J]. Advances in Neural Information Processing Systems 36, 2023.
- [11] Kassner N, Schütze H. Negated and Misprimed Probes for Pretrained Language Models: Birds Can Talk, But Cannot Fly[C]//Jurafsky D, Chai J, Schluter N, et al. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 7811-7818.
- [12] Ji Z, Lee N, Frieske R, et al. Survey of Hallucination in Natural Language Generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.
- [13] Wornow M, Xu Y, Thapa R, et al. The shaky foundations of large language models and foundation models for electronic health records[J]. NPJ Digital Medicine, 2023, 6.
- [14] Jin D, Pan E, Oufattole N, et al. What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams[J]. Applied Sciences, 2021, 11(14): 6421.
- [15] Jin Q, Dhingra B, Liu Z, et al. PubMedQA: A Dataset for Biomedical Research Question Answering[C]//Inui K, Jiang J, Ng V, et al. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Hong Kong, China: Association for Computational Linguistics, 2019: 2567-2577.
- [16] Hendrycks D, Burns C, Basart S, et al. Measuring Massive Multitask Language Understanding [EB/OL]. 2021. <https://arxiv.org/abs/2009.03300>.

- [17] Kıcıman E, Ness R, Sharma A, et al. Causal Reasoning and Large Language Models: Opening a New Frontier for Causality[EB/OL]. 2024. <https://arxiv.org/abs/2305.00050>.
- [18] Elazar Y, Kassner N, Ravfogel S, et al. Measuring and Improving Consistency in Pretrained Language Models[J]. Transactions of the Association for Computational Linguistics, 2021, 9: 1012-1031.
- [19] Kaushik D, Hovy E, Lipton Z C. Learning the Difference that Makes a Difference with Counterfactually-Augmented Data[EB/OL]. 2020. <https://arxiv.org/abs/1909.12434>.
- [20] Dziri N, Lu X, Sclar M, et al. Faith and Fate: Limits of Transformers on Compositionality[EB/OL]. 2023. <https://arxiv.org/abs/2305.18654>.
- [21] Wei J, Wang X, Schuurmans D, et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models[EB/OL]. 2023. <https://arxiv.org/abs/2201.11903>.
- [22] Wang X, Wei J, Schuurmans D, et al. Self-Consistency Improves Chain of Thought Reasoning in Language Models[EB/OL]. 2023. <https://arxiv.org/abs/2203.11171>.
- [23] Turpin M, Michael J, Perez E, et al. Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting[EB/OL]. 2023. <https://arxiv.org/abs/2305.04388>.
- [24] Liévin V, Hother C E, Motzfeldt A G, et al. Can large language models reason about medical questions?[J]. Patterns, 2024, 5(3): 100943.
- [25] Chen Y, Singh V K, Ma J, et al. CounterBench: Evaluating and Improving Counterfactual Reasoning in Large Language Models[EB/OL]. 2025. <https://arxiv.org/abs/2502.11008>.
- [26] Vashishtha A, Dai Q, Mei H, et al. Executable Counterfactuals: Improving LLMs' Causal Reasoning Through Code[EB/OL]. 2025. <https://arxiv.org/abs/2510.01539>.
- [27] Saab K, Tu T, Weng W H, et al. Capabilities of Gemini Models in Medicine[EB/OL]. 2024. <https://arxiv.org/abs/2404.18416>.
- [28] Chen Z, Cano A H, Romanou A, et al. MEDITRON-70B: Scaling Medical Pretraining for Large Language Models[EB/OL]. 2023. <https://arxiv.org/abs/2311.16079>.
- [29] Pal A, Sankarasubbu M. Advancing Open-source Large Language Models in the Medical & Healthcare Domain[EB/OL]. Hugging Face. 2024 [2026-05-24]. <https://huggingface.co/blog/aaditya/openbiollm>.
- [30] Luo R, Sun L, Xia Y, et al. BioGPT: generative pre-trained transformer for biomedical text generation and mining[J]. Briefings in Bioinformatics, 2022, 23(6): bbac409.
- [31] Wu C, Lin W, Zhang X, et al. PMC-LLaMA: Towards Building Open-source Language Models for Medicine[EB/OL]. 2023. <https://arxiv.org/abs/2304.14454>.
- [32] Zhang H, Chen J, Jiang F, et al. HuatuoGPT, towards Taming Language Model to Be a Doctor [EB/OL]. 2023. <https://arxiv.org/abs/2305.15075>.
- [33] Chen Y, Wang Z, Xing X, et al. BianQue: Balancing the Questioning and Suggestion Ability of Health LLMs with Multi-turn Health Conversations Polished by ChatGPT[EB/OL]. 2023. <https://arxiv.org/abs/2310.15896>.
- [34] Yang S, Zhao H, Senbin Z, et al. Zhongjing: Enhancing the Chinese Medical Capabilities of Large Language Model through Expert Feedback and Real-World Multi-Turn Dialogue[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38: 19368-19376.
- [35] Xie J, Yu Y, Chen Y, et al. BenCao: An Instruction-Tuned Large Language Model for Traditional Chinese Medicine[EB/OL]. 2025. <https://arxiv.org/abs/2510.17415>.

- [36] Savage T, Nayak A, Gallo R, et al. Diagnostic reasoning prompts reveal the potential for large language model interpretability in medicine[J]. npj Digital Medicine, 2024, 7.
- [37] Zhou S, Xie W, Li J, et al. Automating Expert-Level Medical Reasoning Evaluation of Large Language Models[EB/OL]. 2025. <https://arxiv.org/abs/2507.07988>.
- [38] Qu Z, Färber M. MediEval: A Unified Medical Benchmark for Patient-Contextual and Knowledge-Grounded Reasoning in LLMs[EB/OL]. 2025. <https://arxiv.org/abs/2512.20822>.
- [39] Li J, Zhong S, Chen K. MLEC-QA: A Chinese Multi-Choice Biomedical Question Answering Dataset[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online: Association for Computational Linguistics, 2021: 8862-8874.
- [40] Wang X, Chen G H, Song D, et al. CMB: A Comprehensive Medical Benchmark in Chinese [EB/OL]. 2024. <https://arxiv.org/abs/2308.08833>.
- [41] Liu M, Hu W, Ding J, et al. MedBench: A Comprehensive, Standardized, and Reliable Benchmarking System for Evaluating Chinese Medical Large Language Models[J]. Big Data Mining and Analytics, 2024, 7: 1116-1128.
- [42] Ouyang Z, Qiu Y, Wang L, et al. CliMedBench: A Large-Scale Chinese Benchmark for Evaluating Medical Large Language Models in Clinical Scenarios[EB/OL]. 2024. <https://arxiv.org/abs/2410.03502>.
- [43] 盛静雯, 史东辉. 面向中文电子病历的医疗问答系统的研究与设计[J]. 电脑知识与技术, 2025, 21(1): 12-15.
- [44] Guan L, Li S. Chinese Medical Q&A Matching Model Based on Multi-Granularity Semantic Information and Knowledge Graph[J]. Journal of Computer Engineering & Applications, 2024, 60(14).
- [45] Zhang Z, Wang X. CMQA20K: Dataset Construction for Chinese Medicine QA Systems Using Artificial Intelligence[C]//2025 Asia-Europe Conference on Cybersecurity, Internet of Things and Soft Computing (CITSC). 2025: 993-999.
- [46] Ghosh R, Gupta A, McBride H, et al. MEDEQUALQA: Evaluating Biases in LLMs with Counterfactual Reasoning[EB/OL]. 2025. <https://arxiv.org/abs/2510.12818>.
- [47] Yasunaga M, Bosselut A, Ren H, et al. Deep Bidirectional Language-Knowledge Graph Pretraining [EB/OL]. 2022. <https://arxiv.org/abs/2210.09338>.
- [48] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[EB/OL]. 2021. <https://arxiv.org/abs/2005.11401>.
- [49] Xiong G, Jin Q, Lu Z, et al. Benchmarking Retrieval-Augmented Generation for Medicine[EB/OL]. 2024. <https://arxiv.org/abs/2402.13178>.
- [50] Zakka C, Chaurasia A, Shad R, et al. Almanac: Retrieval-Augmented Language Models for Clinical Medicine[EB/OL]. 2023. <https://arxiv.org/abs/2303.01229>.
- [51] D'Avila Garcez A, Lamb L C. Neurosymbolic AI: The 3rd Wave[EB/OL]. 2020. <https://arxiv.org/abs/2012.05876>.
- [52] Ribeiro M T, Wu T, Guestrin C, et al. Beyond Accuracy: Behavioral Testing of NLP models with CheckList[EB/OL]. 2020. <https://arxiv.org/abs/2005.04118>.
- [53] NCCN Clinical Practice Guidelines in Oncology: Acute Lymphoblastic Leukemia[A]. Version 1.2022. National Comprehensive Cancer Network, 2022.
- [54] NCCN Clinical Practice Guidelines in Oncology: Small Cell Lung Cancer[A]. Version 1.2023. National Comprehensive Cancer Network, 2023.

- [55] Bunn P, Minna J, Augustyn A, et al. Small Cell Lung Cancer: Can Recent Advances in Biology and Molecular Biology Be Translated into Improved Outcomes?[J]. Journal of Thoracic Oncology, 2016, 11.
- [56] Spirtes P, Glymour C, Scheines R. Causation, Prediction, and Search[M]. 2nd. Cambridge, MA: MIT Press, 2000.
- [57] Kantarjian H, Stein A, Gökbuget N, et al. Blinatumomab versus chemotherapy for advanced acute lymphoblastic leukemia[J]. The New England Journal of Medicine, 2017, 376(9): 836-847.
- [58] NCCN Clinical Practice Guidelines in Oncology: Prostate Cancer[A]. Version 4.2022. National Comprehensive Cancer Network, 2022.
- [59] Albertsen P C, Klotz L, Tombal B, et al. Cardiovascular morbidity associated with gonadotropin releasing hormone agonists and an antagonist[J]. European Urology, 2014, 65(3): 565-573.
- [60] Pearl J. Causal diagrams for empirical research[J]. Biometrika, 1995, 82(4): 669-688.
- [61] Berry D A, Zhou S, Higley H, et al. Association of minimal residual disease with clinical outcome in pediatric and adult acute lymphoblastic leukemia[J]. JAMA Oncology, 2017, 3(7): e170580.
- [62] Pearl J. Probabilistic Reasoning in Intelligent Systems[M]. San Francisco: Morgan Kaufmann, 1988.

附 录

致 谢

值此论文完成之际，谨向所有在课题研究与论文撰写过程中给予我帮助和支持的老师、同学、朋友和家人致以最诚挚的感谢。

首先，衷心感谢我的导师杨旭老师。在论文选题、研究思路、实验设计以及论文撰写过程中，杨老师始终给予我耐心细致的指导和帮助。无论是在学术方向的把握，还是在研究方法与论文规范方面，杨老师都给予了我极大的启发与支持，使我受益匪浅。

同时，特别感谢金子晖学姐在论文研究期间给予我的帮助。从数据集构建、实验设计到论文修改与细节完善，学姐都提供了许多宝贵建议。在我遇到问题与困难时，学姐总是耐心解答，并给予我鼓励与支持，使我能够顺利推进研究工作。

最后，感谢我的家人一直以来对我的理解、支持与鼓励。在我学习和研究过程中，家人始终给予我坚定的支持和温暖的陪伴，使我能够安心完成学业与论文工作。

谨以此文，向所有关心、帮助和支持过我的人致以诚挚的谢意！